

ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN



ĐỀ TÀI:
NHẬN DIỆN CẢM XÚC THÔNG QUA GIỌNG NÓI

BÁO CÁO MÔN KHAI PHÁ DỮ LIỆU (841447)

Nhóm: 1

HỌ TÊN: THÁI MINH KHANG

MSSV: 3122410174

LỚP: DCT1226

TP. HỒ CHÍ MINH, THÁNG 5 NĂM 2025

Mục lục:

DANH MỤC HÌNH ẢNH:	5
Lời mở đầu	6
Lời cảm ơn	7
CHƯƠNG 1: GIỚI THIỆU	1
I. Đặt vấn đề:	1
II. Định nghĩa bài toán và thách thức:	1
III. Các giải pháp thủ công để giải quyết bài toán:	2
IV. Vai trò của khai phá dữ liệu trong việc giải quyết bài toán nhận diện cảm xúc thông qua giọng nói:	3
V. Dự đoán kết quả:	4
VI. Các bài toán tương tự trong thực tế:	5
CHƯƠNG 2: CHUẨN BỊ DỮ LIỆU	6
I. Giới thiệu về bộ dữ liệu:	6
II. Quy cách đặt tên:	6
III. Thống kê:	7
IV. Những giả thiết khi thu thập dữ liệu:	13
CHƯƠNG 3: PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU:	15
I. Quy trình khai phá dữ liệu:	15
1) Biến đổi dữ liệu:	15
2) Tiền xử lý dữ liệu thô:	16
3) Trích xuất đặc trưng:	17
a. MFCC	17
b. Chroma Feature	19
c. Spectrogram:	20
d. Zero-Crossing-Rate (ZCR):	22
e. Spectral features:	23
4) Tiền xử lý dữ liệu:	26
5) Chuẩn bị dữ liệu cho học máy:	27

II. Nguyên lý hoạt động của mô hình:	27
1) Random Forest:	27
2) SVM (Support Vector Machine)	28
3) Voting Ensemble	28
4) XGBoost (Extreme Gradient Boosting)	29
III. Cài đặt mô hình:	30
1) Định nghĩa các mô hình:	30
2) Ý nghĩa các tham số:	31
IV. Tiêu chí đánh giá mô hình:	31
1) Accuracy (độ chính xác):	31
2) Precision (Độ chính xác):	31
3) Recall (Độ phủ/Độ nhạy):	32
4) F1-score:	32
5) Macro Average:	32
6) Weighted Average:	33
CHƯƠNG 4: THỰC NGHIỆM	34
I. Yêu cầu về chương trình:	34
1) Cấu hình:	34
2) Chương trình: Python	34
3) Thư viện:	34
II. Cài đặt:	35
1) Nhập dữ liệu:	35
4) Biến đổi dữ liệu:	35
5) Cắt:	35
6) Lọc nhiễu:	36
7) Kéo dẫn thời gian:	36
8) Trích xuất đặc trưng:	36
9) Làm mịn:	36
10) Chuẩn hóa:	37
11) Padding:	37

CHƯƠNG 5: KẾT QUẢ:	38
I. Kết quả khai phá:	38
II. So sánh với kết quả thực tế:	39
CHƯƠNG 6: TINH CHỈNH:	40
I. Thay đổi cách xử lý dữ liệu:	40
II. Sử dụng GridSearch:	40
III. Kết quả	41
CHƯƠNG 7: THẢO LUẬN VÀ KẾT LUẬN	45
I. Những bài học rút ra khi làm việc với dữ liệu âm thanh	45
II. Khả năng ứng dụng của mô hình	45
III. Ưu, nhược điểm của mô hình:	46
IV. Đề xuất:	46
Tài liệu tham khảo:	48

DANH MỤC HÌNH ẢNH:

Hình 2.1: Phân bố số lượng kênh	8
Hình 2.2: Phân bố tần số lấy mẫu	9
Hình 2.3: Phân bố lớp cảm xúc	10
Hình 2.4: Phân bố thời lượng âm thanh.....	11
Hình 2.5: Phân bố giới tính diễn viên	12
Hình 2.6: Phân bố câu nói.....	13
Hình 3.1: Sơ đồ khai phá dữ liệu.....	15
Hình 3.2: Biểu đồ MFCCs của diễn viên thứ nhất, cảm xúc bình thản.....	18
Hình 3.3: Biểu đồ MFCCs của diễn viên thứ nhất, tám cảm xúc khác nhau.	19
Hình 3.4: Chroma của diễn viên thứ nhất, cảm xúc bình thản.....	20
Hình 3.5: Chroma của diễn viên thứ nhất, tám cảm xúc khác nhau.....	20
Hình 3.6: Biểu đồ Spectrogram của diễn viên thứ nhất, cảm xúc bình thản.....	21
Hình 3.7: Biểu đồ Spectrogram của diễn viên thứ nhất, tám cảm xúc khác nhau....	21
Hình 3.8: Biểu đồ ZCR của diễn viên thứ nhất, cảm xúc bình thản.....	22
Hình 3.9: Biểu đồ của ZCR của diễn viên thứ nhất, tám cảm xúc khác nhau.....	23
Hình 3.10: Biểu đồ tâm phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau....	23
Hình 3.11: Biểu đồ độ rộng phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau.	24
Hình 3.12: Biểu đồ độ tương phản phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau.	25
Hình 3.13: Biểu đồ độ phẳng phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau.....	26

Lời mở đầu

Âm thanh đóng vai trò quan trọng trong cuộc sống hàng ngày, không chỉ đơn thuần là tín hiệu vật lý mà còn là phương tiện truyền tải thông tin, cảm xúc và tương tác xã hội. Trong đó, giọng nói của con người là một trong những dạng âm thanh giàu thông tin nhất. Ngoài nội dung lời nói, giọng nói còn mang theo nhiều đặc điểm cảm xúc như vui vẻ, buồn bã, tức giận, ngạc nhiên,... Việc nhận diện cảm xúc thông qua giọng nói đang ngày càng thu hút sự quan tâm của cộng đồng nghiên cứu vì tiềm năng ứng dụng lớn trong các lĩnh vực như chăm sóc khách hàng, giáo dục, y tế tâm lý, và các hệ thống giao tiếp người-máy.

Nhận diện cảm xúc qua giọng nói là bài toán xử lý tín hiệu âm thanh, trong đó hệ thống cần phân tích các đặc trưng của tín hiệu giọng nói để xác định trạng thái cảm xúc của người nói. Những đặc trưng thường được trích xuất bao gồm MFCC (Mel Frequency Cepstral Coefficients), năng lượng, cao độ (pitch), tốc độ nói, và các đặc điểm phổ khác. Những đặc trưng này giúp thể hiện được các biến đổi tinh tế trong giọng nói gắn liền với từng trạng thái cảm xúc cụ thể.

Trong khuôn khổ báo cáo này, chúng tôi tập trung nghiên cứu và triển khai các kỹ thuật xử lý dữ liệu âm thanh phục vụ cho nhận diện cảm xúc giọng nói, sử dụng các mô hình phân loại truyền thống như K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Decision Tree, và Random Forest. Những mô hình này có ưu điểm là dễ triển khai, dễ giải thích và phù hợp với các bài toán có dữ liệu vừa và nhỏ. Quá trình thực hiện bao gồm các bước chính: tiền xử lý tín hiệu âm thanh, trích xuất đặc trưng, lựa chọn đặc trưng quan trọng, huấn luyện mô hình và đánh giá độ chính xác của từng phương pháp phân loại.

Mục tiêu của báo cáo là cung cấp một cái nhìn tổng quan về quy trình xây dựng hệ thống nhận diện cảm xúc từ giọng nói sử dụng các công cụ và thuật toán có sẵn, không đòi hỏi các mô hình học sâu phức tạp. Qua đó, người đọc có thể hiểu rõ cách thức khai thác thông tin cảm xúc từ tín hiệu âm thanh và áp dụng vào các bài toán thực tiễn với nguồn lực hạn chế. Đây cũng là cơ hội để đánh giá hiệu quả của các phương pháp phân loại truyền thống trong lĩnh vực xử lý âm thanh, từ đó rút ra những bài học và định hướng nghiên cứu cho các ứng dụng trong tương lai.

Lời cảm ơn

Trước tiên, em xin bày tỏ lòng biết ơn chân thành và sâu sắc đến Thạc sĩ Nguyễn Thanh Phước – người đã tận tình hướng dẫn, định hướng và đồng hành cùng em trong suốt quá trình thực hiện báo cáo tốt nghiệp. Những chỉ dẫn chuyên môn quý báu, sự nhiệt tình và trách nhiệm của thầy đã giúp em có thêm động lực, kiến thức và định hướng rõ ràng để hoàn thành đề tài một cách hiệu quả.

Em cũng xin gửi lời cảm ơn đến quý thầy cô trong bộ môn và Trường đại học Sài Gòn đã tạo điều kiện học tập, nghiên cứu thuận lợi trong suốt quá trình học tập và thực hiện đề tài. Sự hỗ trợ và môi trường học tập chuyên nghiệp tại trường là nền tảng quan trọng giúp em tiếp cận kiến thức và phát triển bản thân.

Cuối cùng, em xin chân thành cảm ơn quý bạn đọc đã dành thời gian theo dõi báo cáo này. Mặc dù đã cố gắng hoàn thiện, nhưng chắc chắn không thể tránh khỏi những thiếu sót. Em rất mong nhận được sự thông cảm và những góp ý quý báu từ quý thầy cô và bạn đọc để em có thể rút kinh nghiệm và hoàn thiện hơn trong các nghiên cứu sau này.

CHƯƠNG 1: GIỚI THIỆU

I. Đặt vấn đề:

Trong bối cảnh công nghệ hiện đại, khi nhận diện âm thanh đã trở thành một phần thiết yếu trong nhiều ứng dụng, một bài toán nâng cao và có ý nghĩa đặc biệt là nhận diện cảm xúc thông qua giọng nói. Nếu như việc phân biệt âm thanh của con người và các loại âm thanh khác là bước đầu tiên để máy tính hiểu được môi trường âm thanh xung quanh, thì nhận diện cảm xúc lại là bước tiến xa hơn – giúp máy không chỉ “nghe thấy” mà còn “hiểu được” trạng thái tinh thần của con người.

Trong các nền tảng giao tiếp số như trợ lý ảo (Siri, Alexa), tổng đài thông minh, ứng dụng chăm sóc sức khỏe tinh thần hay hệ thống chăm sóc khách hàng, việc nắm bắt cảm xúc của người dùng thông qua giọng nói mang lại giá trị thực tiễn to lớn. Ví dụ, một trợ lý ảo có thể điều chỉnh phản hồi tùy theo trạng thái cảm xúc của người dùng, hoặc hệ thống tổng đài có thể ưu tiên xử lý các cuộc gọi mang cảm xúc tiêu cực như tức giận hay buồn bã.

Đặc biệt, trong lĩnh vực tâm lý học, nhận diện cảm xúc qua giọng nói đóng vai trò như một công cụ hỗ trợ đắc lực cho các chuyên gia tâm lý trong việc đánh giá, theo dõi và can thiệp tâm lý. Giọng nói có thể phản ánh những thay đổi tinh vi trong cảm xúc mà người đối thoại không thể hiện rõ qua lời nói hay hành vi. Các hệ thống nhận diện tự động có thể hỗ trợ phát hiện sớm dấu hiệu của trầm cảm, lo âu hoặc stress thông qua phân tích giọng nói, từ đó góp phần nâng cao hiệu quả chẩn đoán và điều trị trong tâm lý lâm sàng.

Tuy nhiên, bài toán này cũng đặt ra nhiều thách thức kỹ thuật. Giọng nói của con người rất giàu thông tin nhưng cũng rất đa dạng – phụ thuộc vào ngữ cảnh, ngôn ngữ, giọng vùng miền, tốc độ nói, và đặc biệt là cảm xúc nhất thời. Cảm xúc không chỉ biểu hiện qua từ ngữ mà còn qua các đặc trưng phi ngôn ngữ như cao độ, cường độ, nhịp điệu, và ngắt nghỉ trong giọng nói. Do đó, hệ thống nhận diện cảm xúc qua giọng nói cần có khả năng trích xuất và phân tích những đặc trưng tinh vi này để đưa ra đánh giá chính xác.

II. Định nghĩa bài toán và thách thức:

Bài toán phân loại cảm xúc thông qua giọng nói (Speech Emotion Recognition – SER) nhằm xác định trạng thái cảm xúc của con người dựa trên các tín hiệu âm thanh thu được từ giọng nói. Mục tiêu chính là phân loại giọng nói thành các nhóm cảm xúc cụ thể như: hạnh phúc, buồn bã, tức giận, sợ hãi, trung tính, v.v. Ứng dụng của bài toán này rất đa dạng, từ các hệ thống trợ lý ảo, tổng đài thông minh, chăm sóc khách hàng cho đến hỗ trợ trong lĩnh vực tâm lý học và sức khỏe tinh thần. Cũng giống như bài toán nhận diện

giọng nói, phân loại cảm xúc từ giọng nói thường được thực hiện qua ba bước chính: tiền xử lý dữ liệu, trích xuất đặc trưng, và sử dụng mô hình học máy để phân loại và đánh giá kết quả.

Bước tiền xử lý dữ liệu đóng vai trò quan trọng trong việc loại bỏ nhiễu, chuẩn hóa âm lượng, và cắt đoạn âm thanh để đảm bảo đầu vào nhất quán cho hệ thống phân tích.

Trong bước trích xuất đặc trưng, các đặc trưng âm thanh quan trọng được sử dụng để thể hiện sắc thái cảm xúc trong giọng nói. Một số đặc trưng phổ biến bao gồm: MFCC (Mel-Frequency Cepstral Coefficients), Chroma Features, Zero-Crossing Rate, Energy, Spectral Centroid, Pitch, và Formant cũng thường được sử dụng để mô tả sự biến đổi ngữ điệu, cường độ, và cấu trúc phổ trong giọng nói. Sau khi trích xuất các đặc trưng này, các mô hình học máy sẽ sử dụng dữ liệu đã được xử lý để phân loại cảm xúc. Mỗi mô hình có ưu điểm riêng, tùy thuộc vào loại đặc trưng đầu vào và độ phức tạp của bài toán.

Dữ liệu đầu vào: Là các tệp âm thanh định dạng .wav là một đoạn ghi âm. Trước khi đưa vào mô hình, âm thanh sẽ được tiền xử lý (chuẩn hóa, cắt nhiễu, v.v.) và trích xuất đặc trưng.

Thuật toán: Áp dụng các thuật toán cơ bản để có thể xem được trực quan mức độ tương thích của dữ liệu với mô hình và đánh giá được mô hình nào hoạt động tốt với dữ liệu hơn. Các mô hình được sử dụng Logistic Regression: Mô hình phân loại tuyến tính đơn giản, hoạt động tốt trên đặc trưng MFCC khi số chiều không quá lớn. K-Nearest Neighbors (KNN): Phân loại dựa trên khoảng cách giữa các điểm đặc trưng âm thanh, đơn giản và dễ triển khai. Support Vector Machine (SVM): Thường đạt hiệu suất cao với tập đặc trưng nhỏ và rõ ràng như MFCC. Phù hợp với bài toán phân loại đa lớp. Decision Tree: Mô hình đơn giản, dễ giải thích, phân loại dựa trên các điều kiện ngưỡng đặc trưng âm thanh. Convolutional Neural Network (CNN): Mô hình học sâu cơ bản, dùng khi đầu vào được chuyển sang dạng hình ảnh (ví dụ: Mel-spectrogram). Mạnh trong việc tự động học đặc trưng từ dữ liệu âm thanh.

III. Các giải pháp thủ công để giải quyết bài toán:

Trước khi các mô hình học máy và học sâu trở nên phổ biến, bài toán phân loại cảm xúc qua giọng nói thường được giải quyết bằng các giải pháp thủ công (rule-based hoặc đặc trưng được thiết kế bằng tay). Những phương pháp này tập trung vào việc phân tích các đặc điểm âm thanh cụ thể và xây dựng các luật phân loại dựa trên kinh nghiệm hoặc kiến thức chuyên môn. Một số giải pháp thủ công sẽ được đề cập ngay sau đây:

Luật phân loại dựa trên ngưỡng là một phương pháp thủ công phổ biến trong giai đoạn đầu của nghiên cứu phân loại cảm xúc từ giọng nói. Phương pháp này hoạt động dựa trên giả định rằng các cảm xúc khác nhau sẽ có các biểu hiện đặc trưng trong giọng nói - chẳng hạn như sự thay đổi về cao độ, năng lượng, tốc độ nói hoặc độ rộng phổ tần số. Dựa vào đó, các nhà nghiên cứu đặt ra các giá trị ngưỡng cho từng đặc trưng âm học để phân loại cảm xúc. Ví dụ, nếu pitch (cao độ) của giọng nói vượt qua một ngưỡng nhất định và năng lượng (energy) cũng cao, giọng nói có thể được suy đoán là mang cảm xúc vui, phấn khích hoặc ngạc nhiên. Ngược lại, nếu pitch thấp, năng lượng nhỏ và tốc độ nói chậm, giọng nói có thể được phân loại là buồn hoặc mệt mỏi. Một số luật khác có thể dựa vào đặc trưng Zero-Crossing Rate, trong đó tỷ lệ vượt mức âm có thể phản ánh mức độ dao động và thay đổi của cảm xúc. Việc áp dụng các ngưỡng cố định cho từng đặc trưng giúp việc phân loại trở nên dễ hiểu và có thể lý giải được.

Phân cụm đặc trưng bằng trực quan hoặc phương pháp đơn giản là cách tiếp cận thủ công trong đó các đặc trưng âm thanh được trích xuất và trực quan hóa (thường bằng biểu đồ scatter hoặc giảm chiều như PCA, t-SNE) để quan sát sự phân bố của các cảm xúc. Từ đó, người phân tích có thể chia dữ liệu thành các cụm tương ứng với từng loại cảm xúc. Ví dụ, các điểm có pitch cao và năng lượng lớn thường tập trung thành một nhóm, có thể gán nhãn là “vui” hoặc “ngạc nhiên”. Phương pháp này đơn giản, dễ áp dụng trong bước khám phá dữ liệu, nhưng mang tính cảm quan và không hiệu quả với tập dữ liệu lớn hoặc phức tạp.

Các phương pháp thủ công đa số sẽ áp dụng kiến thức chuyên môn về ngôn ngữ học và tâm lý học để đưa ra một số quy tắc nhất định trong việc phân loại cảm xúc. Việc này dẫn đến các kết quả có thể mang yếu tố chủ quan hơn và các yếu tố khách quan như: giọng nói bị ảnh hưởng bởi ngữ cảnh, tiếng ồn, vùng miền hoặc phong cách cá nhân của người nói. Ngoài ra, cảm xúc là yếu tố mang tính liên tục và đa chiều, nên việc chia ranh giới rõ ràng giữa các trạng thái cảm xúc dựa vào ngưỡng tĩnh thường dẫn đến độ chính xác thấp và không phản ánh được sự linh hoạt của biểu cảm giọng nói trong đời thực.

IV. Vai trò của khai phá dữ liệu trong việc giải quyết bài toán nhận diện cảm xúc thông qua giọng nói:

Nhận diện cảm xúc qua giọng nói nhằm phân tích các đặc trưng âm thanh như cao độ (pitch), nhịp điệu (rhythm), cường độ (intensity), và các đặc điểm phổ (spectral features) để xác định trạng thái cảm xúc của người nói, chẳng hạn như vui, buồn, tức giận hay lo lắng. Khai phá dữ liệu hỗ trợ quá trình này thông qua việc trích xuất, phân tích và xây dựng các mô hình dự đoán từ khối lượng lớn dữ liệu giọng nói, từ đó cải thiện độ chính xác và khả năng ứng dụng thực tiễn.

Đầu tiên, khai phá dữ liệu cho phép trích xuất các đặc trưng quan trọng từ dữ liệu âm thanh thô. Các kỹ thuật như phân tích phổ, chuyển đổi Fourier, hay Mel-frequency cepstral coefficients (MFCC) được sử dụng để biến đổi tín hiệu giọng nói thành các tập hợp đặc trưng có ý nghĩa. Khai phá dữ liệu giúp xác định những đặc trưng nào có mối liên hệ chặt chẽ với các trạng thái cảm xúc cụ thể, đồng thời loại bỏ các yếu tố nhiễu như tiếng ồn nền hay sự khác biệt về giọng nói giữa các cá nhân. Ví dụ, thuật toán phân cụm (clustering) có thể nhóm các mẫu giọng nói có đặc điểm tương đồng để xác định các mô hình cảm xúc chung. Thứ hai, khai phá dữ liệu hỗ trợ xây dựng các mô hình học máy và học sâu để dự đoán cảm xúc. Các thuật toán như cây quyết định (decision trees), mạng nơ-ron nhân tạo (artificial neural networks), hay máy vector hỗ trợ (support vector machines) được huấn luyện trên các tập dữ liệu lớn, chẳng hạn như IEMOCAP hay RAVDESS, để học cách ánh xạ đặc trưng giọng nói với các nhãn cảm xúc. Quá trình này đòi hỏi khai phá dữ liệu để xử lý các vấn đề như dữ liệu mất cân bằng (imbalanced data) hoặc dữ liệu bị nhiễu, qua đó tối ưu hóa hiệu suất mô hình. Các kỹ thuật như khai phá luật kết hợp (association rule mining) cũng có thể được áp dụng để khám phá mối quan hệ tiềm ẩn giữa các đặc trưng âm thanh và cảm xúc, ví dụ như sự kết hợp giữa cao độ cao và nhịp nhanh thường xuất hiện trong trạng thái phấn khích. Cuối cùng, khai phá dữ liệu giúp cải thiện khả năng cá nhân hóa và thích nghi của hệ thống nhận diện cảm xúc. Bằng cách phân tích dữ liệu giọng nói theo thời gian thực, các hệ thống có thể học hỏi và điều chỉnh mô hình dựa trên đặc điểm riêng của từng người dùng, từ đó nâng cao độ chính xác trong các ứng dụng như trợ lý ảo, chăm sóc khách hàng, hay hỗ trợ sức khỏe tâm lý. Ngoài ra, khai phá dữ liệu còn hỗ trợ phát hiện các xu hướng cảm xúc trong tập hợp lớn, ví dụ như phân tích cảm xúc của đám đông trong các sự kiện công cộng.

Tóm lại, khai phá dữ liệu là nền tảng không thể thiếu trong việc nhận diện cảm xúc qua giọng nói, từ việc trích xuất đặc trưng, xây dựng mô hình dự đoán, đến tối ưu hóa và cá nhân hóa hệ thống. Vì vậy nên nó đóng vai trò quan trọng trong việc phát triển và nâng cao hiệu quả của các hệ thống nhận diện cảm xúc thông qua giọng nói, một lĩnh vực đang nhận được sự quan tâm lớn trong trí tuệ nhân tạo và tương tác người-máy. Nhờ vào các kỹ thuật khai phá dữ liệu, các hệ thống này không chỉ đạt được độ chính xác cao mà còn mở ra tiềm năng ứng dụng rộng rãi trong nhiều lĩnh vực, từ công nghệ đến y tế và giáo dục.

V. Dự đoán kết quả:

Chúng tôi kỳ vọng mô hình sẽ thể hiện khả năng nhận diện chính xác ít nhất 6 trên tổng số 8 trạng thái cảm xúc đa dạng (bao gồm bình thường, bình tĩnh, vui vẻ, buồn bã, giận dữ, sợ hãi, ghê tởm và ngạc nhiên). Đây là một minh chứng cho khả năng nắm bắt và phân biệt các sắc thái biểu cảm khác nhau của giọng nói, vượt qua những ranh giới mơ hồ giữa các cung bậc tình cảm.

Về độ chính xác tổng thể, mục tiêu mà chúng tôi hướng đến là khoảng 80% (0.8). Một kết quả như vậy sẽ khẳng định sức mạnh của mô hình trong việc đưa ra những dự đoán đáng tin cậy về trạng thái cảm xúc của người nói. Hãy tưởng tượng, với độ chính xác này, hệ thống của chúng ta có thể hiểu được sự thay đổi trong tâm trạng của một người đang tương tác, từ đó mở ra những ứng dụng trong trợ lý ảo thông minh, có khả năng phản hồi một cách đồng cảm và phù hợp. Hỗ trợ trong các ứng dụng y tế và tâm lý học, giúp các chuyên gia đánh giá và theo dõi trạng thái cảm xúc của bệnh nhân một cách khách quan. Nâng cao trải nghiệm người dùng trong các ứng dụng giải trí, ví dụ như tự động điều chỉnh nội dung hoặc gợi ý dựa trên cảm xúc của người dùng.

VI. Các bài toán tương tự trong thực tế:

Nhận diện giọng nói trong môi trường ồn ào (Speech Enhancement): Các ứng dụng của nó bao gồm cải thiện chất lượng cuộc gọi trong các môi trường ồn ào, như sân bay, văn phòng mở hoặc trên đường. Ứng dụng: Các hệ thống như Zoom sử dụng công nghệ cải thiện giọng nói trong môi trường ồn ào để giúp các cuộc gọi rõ ràng hơn.

Nhận diện âm thanh (Sound Event Detection): Đây là bài toán phân loại các âm thanh từ môi trường xung quanh, chẳng hạn như tiếng va đập, tiếng còi xe, tiếng bước chân, hoặc tiếng cửa mở. Ứng dụng: DeepMind đã phát triển hệ thống nhận diện các âm thanh môi trường cho các ứng dụng giám sát an ninh.

Phân loại âm thanh môi trường (Environmental Sound Classification): Tương tự như nhận diện âm thanh, nhưng bài toán này chú trọng vào phân loại các âm thanh môi trường. Ví dụ, xác định loại âm thanh như tiếng mưa, tiếng sóng vỗ, tiếng chim hót, hoặc tiếng đồ vỡ. Ứng dụng: Google sử dụng phân loại âm thanh môi trường trong ứng dụng Sound Search để nhận diện nhạc từ âm thanh môi trường.

Nhận diện cảm xúc qua giọng nói (Speech Emotion Recognition): Ứng dụng: Cogito sử dụng nhận diện cảm xúc trong giọng nói để cải thiện chất lượng cuộc gọi chăm sóc khách hàng.

Tự động tách lời (Voice Activity Detection - VAD): Bài toán này liên quan đến việc phát hiện các đoạn có giọng nói trong tín hiệu âm thanh và loại bỏ các phần không có giọng nói (chẳng hạn như im lặng hoặc tiếng nền). Các ứng dụng của nó bao gồm việc cải thiện chất lượng âm thanh trong các hệ thống thoại, giảm thiểu độ trễ trong các ứng dụng nhận dạng giọng nói, và tăng cường hiệu suất cho các mô hình học máy. Ứng dụng: Google Speech-to-Text sử dụng VAD để chỉ nhận diện và chuyển đổi lời nói, loại bỏ các đoạn không có giọng nói.

CHƯƠNG 2: CHUẨN BỊ DỮ LIỆU

I. Giới thiệu về bộ dữ liệu:

Bộ dữ liệu của Ryerson Audio-Visual Database of Emotional Speech and Song) chứa 7.356 tệp (tổng kích thước: 24,8 GB). Bộ dữ liệu chứa 24 diễn viên chuyên nghiệp (12 nữ, 12 nam), phát âm và từ vựng phù hợp trong giọng Bắc Mỹ trung lập. Các cảm xúc bao gồm bình tĩnh, vui vẻ, buồn bã, tức giận, sợ hãi, bất ngờ, ghê tởm, và bài hát chứa đựng những cảm xúc bình tĩnh, vui, buồn, tức giận và đáng sợ. Mỗi biểu cảm được tạo ra ở hai cấp độ cường độ cảm xúc (bình thường, mạnh mẽ), với một biểu thức trung tính bổ sung. Tất cả các điều kiện đều có sẵn ở ba định dạng phương thức: chỉ âm thanh (16 bit, 48kHz .wav), âm thanh-video (720p H.264, AAC 48KHz, .MP4) và chỉ có video (không có âm thanh). Lưu ý, không có tệp bài hát cho Actor_18.

Bộ dữ liệu được sử dụng sẽ trích xuất từ bộ dữ liệu trên bao gồm 24 thư mục, mỗi thư mục tương ứng với một diễn viên. Tổng cộng có 1440 file âm thanh .wav, bao gồm các đoạn thoại ngắn (khoảng 3-5 giây) thể hiện 7 trạng thái cảm xúc chính: bình tĩnh, vui vẻ, buồn bã, tức giận, sợ hãi, ngạc nhiên và chán ghét, cùng với trạng thái trung t tạo ra sự đa dạng trong cách thể hiện. Được thiết kế để giải quyết các bài toán nhận diện cảm xúc thông qua giọng nói và biểu cảm khuôn mặt, đặc biệt tập trung vào nhận diện cảm xúc từ âm thanh giọng nói. Các file âm thanh được ghi lại ở định dạng WAV, đảm bảo chất lượng âm thanh cao, phù hợp cho việc xử lý và phân tích. Dữ liệu được thu thập từ các buổi ghi âm được kiểm soát chặt chẽ, với các diễn viên thể hiện các câu nói và bài hát theo các kịch bản được chuẩn hóa, và được lưu trữ công khai trên các nền tảng như Zenodo.

Bộ dữ liệu RAVDESS là một tài nguyên quý giá cho việc nghiên cứu và phát triển các mô hình nhận diện cảm xúc, với tiềm năng ứng dụng trong các lĩnh vực như tương tác người-máy, trợ lý ảo thông minh, phân tích tâm lý, hoặc cải thiện trải nghiệm khách hàng. Mặc dù nhận diện cảm xúc qua giọng nói là một lĩnh vực hấp dẫn với nhiều ứng dụng thực tiễn, việc tìm kiếm bộ dữ liệu chất lượng cao cho bài toán này không phải lúc nào cũng dễ dàng. Nhiều bộ dữ liệu hiện có thường thiếu sự đa dạng về cảm xúc hoặc bị giới hạn về số lượng mẫu. Do đó, RAVDESS ra đời nhằm cung cấp một bộ dữ liệu đa dạng và được ghi âm chuyên nghiệp, với số lượng diễn viên và trạng thái cảm xúc lớn, hỗ trợ các nhà nghiên cứu và kỹ sư thử nghiệm, đánh giá và cải thiện các thuật toán nhận diện cảm xúc thông qua giọng nói.

Link kaggle: <https://www.kaggle.com/datasets/uwrfkagglerravdess-emotional-speech-audio>

II. Quy cách đặt tên:

Quy cách đặt tên file trong RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song) bao gồm 1440 file, mỗi file mang tên duy nhất theo định dạng 7 phần số, phân cách bằng dấu gạch nối (ví dụ: 03-01-06-01-02-01-12.wav). Các phần này mã hóa thông tin cụ thể về đặc điểm dữ liệu:

Phần 1: Phương thức (01 = âm thanh và video, 02 = chỉ video, 03 = chỉ âm thanh).

Phần 2: Kênh giọng (01 = lời nói, 02 = bài hát).

Phần 3: Cảm xúc (01 = neutral, 02 = calm, 03 = happy, 04 = sad, 05 = angry, 06 = fearful, 07 = disgust, 08 = surprised).

Phần 4: Cường độ cảm xúc (01 = normal, 02 = strong; cảm xúc neutral chỉ có cường độ normal).

Phần 5: Câu nói (01 = "Kids are talking by the door", 02 = "Dogs are sitting by the door").

Phần 6: Lần lặp (01 = lần 1, 02 = lần 2).

Phần 7: Diễn viên (01 đến 24; số lẻ là nam, số chẵn là nữ).

Lưu ý đặc biệt: Trong báo cáo này, chỉ sử dụng dữ liệu âm thanh lời nói, tương ứng với phần 1 = 03 (chỉ âm thanh) và phần 2 = 01 (lời nói), nhằm tập trung vào phân tích đặc trưng âm thanh của lời nói cảm xúc.

Ví dụ minh họa: 03-01-06-01-02-01-12.wav

Chỉ âm thanh (03)

Lời nói (01)

Cảm xúc fearful (06)

Cường độ normal (01)

Câu nói "Dogs are sitting by the door" (02)

Lần lặp 1 (01)


Diễn viên 12 (nữ, do ID là số chẵn).

III. Thống kê:

Tổng quan:

file_path	1440
emotion	8
emotion_idx	8
gender	2
intensity	2
statement	2
actor_id	24
repetition	2
sample rate	1

Số lượng kênh:




Số lượng tệp mono: 1440
Số lượng tệp stereo: 0

Hình 2.1: Phân bố số lượng kênh

Monochrome: Âm thanh được ghi lại từ một nguồn duy nhất (một micro) và phát ra cùng một tín hiệu qua tất cả các loa. Điều này có nghĩa là âm thanh không có sự khác biệt giữa các hướng (left và right), phù hợp với các ứng dụng đơn giản như nhận diện giọng nói, nơi không cần tái tạo không gian âm thanh. Trong RAVDESS, định dạng mono được sử dụng để tập trung vào nội dung cảm xúc mà không bị ảnh hưởng bởi hiệu ứng không gian.

Thống kê tần số lấy mẫu:

Tần số lấy mẫu phổ biến:
sample_rate
48000 1440



Hình 2.2: Phân bố tần số lấy mẫu

Chỉ có một tần số lấy mẫu (sampling rate) duy nhất là 48000 Hz – tần số lấy mẫu chuẩn cho các video, phim, truyền hình, audio.


Số lượng mẫu theo từng loại cảm xúc:

surprised	192
disgust	192
fearful	192
sad	192
happy	192
calm	192
angry	192
neutral	96

Tổng số mẫu: 1440

Tỷ lệ mỗi lớp cảm xúc: (Đơn vị %)

surprised	13.33
disgust	13.33
fearful	13.33
sad	13.33
happy	13.33
calm	13.33
angry	13.33
neutral	6.67



Hình 2.3: Phân bố lớp cảm xúc

Có thể nhận thấy rằng sự phân bố giữa các lớp cảm xúc tương đối đồng đều, ngoại trừ lớp neutral có tỷ lệ thấp hơn do chỉ biểu đạt ở mức độ bình thường mà không có cường độ mạnh.


Thống kê thời lượng âm thanh trong mỗi audio:

Thời lượng trung bình: 3.70 giây

Độ lệch chuẩn: 0.34 giây

Thời lượng tối thiểu: 2.94 giây

Thời lượng tối đa: 5.27 giây




Hình 2.4: Phân bố thời lượng âm thanh

Phân bố thời lượng âm thanh trong dữ liệu tập trung chủ yếu quanh giá trị trung bình 3,70 giây, với đỉnh cao nhất tại khoảng 3,5-4,0 giây, cho thấy phần lớn các tệp có độ dài tương đối đồng đều. Tuy nhiên, có một số ít tệp kéo dài trên 4,5 giây, tạo thành phần đuôi phải làm mất đi phân phối chuẩn, có thể cần xem xét khi chuẩn hóa dữ liệu để tránh ảnh hưởng đến mô hình.

Thống kê giới tính diện viên:

```
gender
female    720
male      720
Name: count, dtype: int64
Tỷ lệ giới tính (%):
gender
female    50.0
male      50.0
Name: count, dtype: float64
```



Hình 2.5: Phân bố giới tính diễn viên


Phân bố số lượng mẫu theo giới tính trong dữ liệu cho thấy sự cân bằng hoàn hảo giữa nữ (720) và nam (720), với tỷ lệ mỗi giới đạt 50%. Điều này đảm bảo rằng mô hình nhận diện cảm xúc không bị thiên lệch theo giới tính khi huấn luyện.

Thống kê câu nói:

```

statement
Kids are talking by the door    720
Dogs are sitting by the door   720
Name: count, dtype: int64
Tỷ lệ câu nói (%):
statement
Kids are talking by the door    50.0
Dogs are sitting by the door   50.0
Name: count, dtype: float64

```



Hình 2.6: Phân bố câu nói

Phân phối đều 50:50 cho hai câu nói, nhằm tập trung vào cảm xúc trong âm thanh hơn là về mặt ngữ nghĩa.

IV. Những giả thiết khi thu thập dữ liệu:

Tính xác thực của cảm xúc: Giả định rằng các diễn viên trong RAVDESS đã thể hiện cảm xúc một cách chân thực, phản ánh đúng các đặc điểm giọng nói đặc trưng của từng cảm xúc trong thực tế. Tuy nhiên, do đây là diễn xuất, các cảm xúc có thể được khuếch

đại so với giọng nói tự nhiên, dẫn đến khả năng mô hình học được các đặc trưng hơi phóng đại hơn so với tình huống thực tế.

Tính đồng nhất: Các mẫu âm thanh trong bộ dữ liệu được ghi lại trong điều kiện phòng thu chuyên nghiệp với thiết bị chất lượng cao, giả định rằng không có nhiễu nền hoặc biến đổi âm thanh không mong muốn, đảm bảo sự nhất quán về chất lượng. Ngoài ra, tất cả diễn viên sử dụng tiếng Anh Bắc Mỹ, với giả định rằng đặc điểm giọng nói giữa các diễn viên là đồng nhất trong ngữ cảnh ngôn ngữ này.


Tính đại diện: Bộ dữ liệu RAVDESS giả định rằng 8 cảm xúc được chọn (neutral, calm, happy, sad, angry, fearful, disgust, surprised) bao quát đầy đủ các trạng thái cảm xúc chính trong giao tiếp bằng giọng nói. Đồng thời, giả định rằng hai câu nói ("Kids are talking by the door" và "Dogs are sitting by the door") mang tính đa dạng đủ để thể hiện các mẫu giọng nói cảm xúc khác nhau.

Tính cân bằng giới tính: Bộ dữ liệu giả định rằng sự cân bằng giữa nam và nữ, với 12 diễn viên mỗi giới, giúp mô hình học được các đặc trưng cảm xúc mà không bị thiên lệch theo giới tính, đảm bảo tính công bằng trong việc nhận diện.

Hạn chế: Một hạn chế lớn là bộ dữ liệu chỉ tập trung vào tiếng Anh Bắc Mỹ, thiếu các biến thể văn hóa hoặc ngôn ngữ khác, có thể làm giảm khả năng tổng quát hóa sang các ngữ cảnh đa dạng. Ngoài ra, mặc dù cảm xúc neutral có số lượng mẫu ít hơn, giả định rằng điều này không ảnh hưởng đáng kể đến phân tích, nhưng trong thực tế, việc cân bằng dữ liệu có thể cần thiết để cải thiện hiệu quả mô hình.

CHƯƠNG 3: PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU:

I. Quy trình khai phá dữ liệu:



Hình 3.1: Sơ đồ khai phá dữ liệu

Đầu ra cho bài toán này là 8 nhãn cảm xúc khác nhau. Tùy theo bài toán và dữ liệu mà có thể có quy trình, cách xử lý khác nhau. Hình là bảng quy trình chung nhất cho dữ liệu âm thanh.

1) Biến đổi dữ liệu:

Sau khi hoàn thành bước thu thập dữ liệu âm thanh dưới dạng sóng dao động, chúng ta chuyển sang giai đoạn biến đổi dữ liệu. Âm thanh thuộc nhóm dữ liệu phi cấu trúc, do đó, để có thể xử lý và áp dụng các thuật toán học máy, cần chuyển đổi tín hiệu âm thanh từ dạng sóng analog sang dạng số (digital). Quá trình này bao gồm việc rời rạc hóa tín hiệu

liên tục thành các giá trị số, tạo thành một mảng dữ liệu có cấu trúc phù hợp cho các bước tiền xử lý và trích xuất đặc trưng tiếp theo.

Việc chuyển đổi này không chỉ giúp chuẩn hóa dữ liệu mà còn mở ra khả năng áp dụng các kỹ thuật xử lý tín hiệu số hiện đại, từ đó nâng cao hiệu quả của mô hình học máy trong các tác vụ như nhận dạng giọng nói, phân loại âm thanh, hoặc khử nhiễu.

2) Tiền xử lý dữ liệu thô:

Chuẩn hóa biên độ là bước quan trọng để đảm bảo tất cả các tín hiệu âm thanh có cùng thang đo, thường được đưa về khoảng $[-1, 1]$ hoặc $[0, 1]$. Quá trình này giúp loại bỏ sự chênh lệch âm lượng giữa các mẫu do khác biệt về thiết bị thu âm hoặc khoảng cách từ nguồn phát đến micro. Kỹ thuật phổ biến nhất là chia tất cả các giá trị biên độ cho giá trị tuyệt đối lớn nhất trong tín hiệu. Ngoài ra, một số phương pháp khác như RMS normalization hoặc Peak normalization cũng được sử dụng tùy vào mục đích ứng dụng. Việc chuẩn hóa giúp mô hình học máy ổn định hơn, tránh hiện tượng một số mẫu có biên độ quá lớn chi phối quá trình huấn luyện.

Lọc nhiễu: Âm thanh thu được từ môi trường thực thường chứa nhiều tạp âm như tiếng ồn nền, tiếng gió, hoặc nhiễu điện tử từ thiết bị. Để làm sạch tín hiệu, các kỹ thuật như Spectral Subtraction, Wiener Filtering, hoặc Spectral Gating (sử dụng thư viện `noisereduce`) được áp dụng. Các phương pháp này hoạt động bằng cách phân tích phổ tần số của nhiễu và loại bỏ các thành phần không mong muốn. Gần đây, các mô hình Deep Learning (như DNN hoặc U-Net) cũng được sử dụng để khử nhiễu hiệu quả hơn, đặc biệt trong các ứng dụng như xử lý giọng nói hoặc âm thanh y tế.

Chia khung (Framing) & Cửa sổ hóa (Windowing): Do tín hiệu âm thanh là dữ liệu liên tục, ta cần chia nó thành các khung ngắn (thường 20–40ms) để phân tích tín hiệu trong miền tần số. Tuy nhiên, việc chia khung đột ngột có thể gây hiện tượng rò rỉ phổ (spectral leakage), làm méo tín hiệu. Để giảm thiểu vấn đề này, các hàm cửa sổ như Hamming, Hanning, hoặc Blackman được áp dụng để làm mịn các cạnh của khung. Mỗi hàm cửa sổ có ưu nhược điểm khác nhau: Hamming phổ biến trong xử lý tiếng nói, trong khi Hanning thích hợp cho phân tích nhạc cụ.

Cân bằng âm sắc (Equalization): Một số tần số trong âm thanh có thể bị lệch do đặc tính micro hoặc môi trường thu âm. Cân bằng âm sắc (EQ) giúp điều chỉnh lại các dải tần để tín hiệu trung thực hơn. Ví dụ, trong nhận dạng giọng nói, các tần số 300–3400 Hz (dải thoại) thường được tăng cường, trong khi tần số thấp (dưới 100 Hz) có thể bị giảm để loại bỏ tiếng ồn. Các bộ lọc thông dụng bao gồm Low-pass, High-pass, hoặc Band-pass filters, tùy thuộc vào ứng dụng cụ thể.

Lấy mẫu lại (Resampling): Các tệp âm thanh có thể được thu ở nhiều tần số lấy mẫu khác nhau (8kHz, 16kHz, 44.1kHz...). Để đồng bộ hóa dữ liệu, ta thường giảm tần số lấy mẫu (downsampling) hoặc tăng tần số (upsampling) về một giá trị chuẩn (ví dụ 16kHz cho giọng nói). Quá trình này sử dụng các bộ lọc chống chồng phổ (anti-aliasing) để tránh làm méo tín hiệu. Resampling không chỉ giúp giảm kích thước dữ liệu mà còn đảm bảo tính nhất quán khi đưa vào mô hình học máy.

3) Trích xuất đặc trưng:

Chúng ta sẽ thực hiện 5 phương pháp trích xuất đặc trưng chính, bao gồm: MFCCs, Spectrogram, Chroma Feature, Spectral, Zero. Mỗi phương pháp này đóng một vai trò quan trọng trong việc mô tả và phân biệt các đặc trưng âm thanh, góp phần vào việc nâng cao độ chính xác của hệ thống nhận diện. Những đặc trưng này sẽ giúp chúng ta phát hiện và phân loại các đặc tính âm thanh một cách hiệu quả hơn, tạo nền tảng vững chắc cho các mô hình học máy.

Tuy nhiên ở báo cáo sẽ đi sâu vào MFCCs, bốn cách trích xuất còn lại chỉ dừng lại ở việc hiểu cách thức thực hiện và đọc sơ đồ trực quan.

a. MFCC

MFCC (Mel-Frequency Cepstral Coefficients) là một trong những phương pháp trích xuất đặc trưng âm thanh phổ biến nhất, đặc biệt hiệu quả trong các bài toán xử lý tiếng nói và nhận dạng âm thanh. Đặc trưng này được xây dựng dựa trên nguyên lý mô phỏng cách tai người cảm nhận tần số, giúp biểu diễn tín hiệu âm thanh dưới dạng các hệ số đặc trưng có ý nghĩa về mặt âm học.

Quá trình trích xuất MFCC bắt đầu bằng việc chia tín hiệu âm thanh thành các khung ngắn (thường từ 20-40ms) và áp dụng hàm cửa sổ (như Hamming hoặc Hanning) để giảm hiện tượng rò rỉ phổ. Mỗi khung tín hiệu sau đó được chuyển sang miền tần số bằng phép biến đổi Fourier nhanh (FFT), tạo ra phổ công suất biểu diễn năng lượng âm thanh tại các tần số khác nhau.

Một trong những điểm đặc biệt của MFCC là sử dụng thang Mel - một thang đo tần số phi tuyến tính mô phỏng cách tai người cảm nhận âm thanh. Thang Mel được tính toán theo công thức:

$$f_{mel} = 2595 \log_{10} \left(1 + \frac{f}{700} \right)$$

Trong đó f là tần số tuyến tính (Hz). Dựa trên thang này, một bộ lọc gồm 20-40 bộ lọc tam giác (Mel filterbank) được áp dụng lên phổ công suất, với các bộ lọc tập trung dày đặc hơn ở vùng tần số thấp (0-1000 Hz) - nơi tai người nhạy cảm nhất.

Sau khi áp dụng bộ lọc Mel, năng lượng tại mỗi băng tần được tính toán và chuyển sang thang logarit để nén dải động:

$$S[m] = \log \left(\sum_{k=0}^{N-1} |X[k]|^2 * H_m[k] \right)$$

với $X[k]$ là phổ FFT, $H_m[k]$ là hàm trọng số của bộ lọc Mel thứ m . Cuối cùng, phép biến đổi cosine rời rạc (DCT) được áp dụng để thu được các hệ số cepstral:


$$c[n] = \sum_{m=1}^M S[m] * \cos \left(\frac{\pi * n * (m - 0.5)}{M} \right)$$

Trong đó $c[n]$ là các hệ số MFCC, thường chỉ giữ lại 12-13 hệ số đầu tiên do chứa thông tin quan trọng nhất về phổ âm thanh.

MFCC không chỉ cung cấp thông tin về phổ tần số mà còn tách biệt thông tin về nguồn phát âm thanh (như dây thanh quản) khỏi thông tin về bộ lọc (hình dạng ống thanh quản và khoang miệng). Điều này làm cho MFCC đặc biệt hữu ích trong nhận dạng giọng nói, nơi cần tập trung vào đặc điểm phát âm hơn là đặc điểm vật lý của người nói.

Để tăng cường hiệu suất, người ta thường bổ sung các đặc trưng động (delta và delta-delta) thể hiện sự thay đổi của các hệ số MFCC theo thời gian. Các đặc trưng này được tính bằng cách lấy đạo hàm bậc nhất và bậc hai của chuỗi MFCC theo thời gian, giúp mô hình nắm bắt được sự biến đổi âm sắc trong lời nói.


Heatmap sau khi trích xuất đặc trưng từ MFCCs của file 1 (diễn viên 1, cảm xúc bình thản):



Hình 3.2: Biểu đồ MFCCs của diễn viên thứ nhất, cảm xúc bình thản.

Âm thanh từ giây thứ 1 đến giây thứ 2.5 có mức dB thay đổi lớn, trải dài từ >0 dB đến -600 dB, cho thấy những giây này của audio có âm thanh, phần còn lại trên biểu đồ hầu như không có âm thanh gì vì không có dao động nào được ghi nhận.

Cho các audio tiếp theo:




Hình 3.3: Biểu đồ MFCCs của diễn viên thứ nhất, tám cảm xúc khác nhau.

Kích thước của mảng tín hiệu ban đầu file thứ nhất: (72838,)

Kích thước của mảng tín hiệu sau khi sử dụng MFCCs: (13, 143) - 13 là hệ số MFCCs.

b. Chroma Feature


Chroma Feature là một phương pháp trích xuất đặc trưng âm thanh tập trung vào cao độ (pitch) của âm nhạc hoặc giọng nói. Nó biểu diễn tín hiệu âm thanh dựa trên 12 nốt nhạc trong thang âm phương Tây (C, C#, D,..., B), bất kể quãng tám (octave) nào.



Hình 3.4: Chroma của diễn viên thứ nhất, cảm xúc bình thản.

Ở đây các vạch mức chroma rõ ràng hơn, ta có thể thấy từ 1-2.5s đầu tiên đặc trưng âm thanh chủ yếu ở nốt D (rê) và đi dần đến A (la) trong heatmap (màu xanh), xung quanh giây còn lại hầu hết là không có tín hiệu âm thanh – có màu đỏ cam.

Heatmap về đặc trưng chroma cho 8 audio tiếp theo:



Hình 3.5: Chroma của diễn viên thứ nhất, tám cảm xúc khác nhau.

Từ việc phân bổ các nốt, ta có thể thấy giọng người này khá thấp. Có thể đoán đây là nam.


Trích xuất đặc trưng chroma giúp: xác định hợp âm và giai điệu, phân tích cấu trúc âm nhạc, nhận diện các mô hình âm nhạc. Và vì giọng nói con người cũng có các bản chất của các nhạc cụ như tuần hoàn, âm sắc rõ ràng nên cách trích xuất này cũng có thể áp dụng.

c. Spectrogram:

Spectrogram biểu diễn phổ tần số - spectrum của tín hiệu âm thanh theo cả tần số và thời gian. Nó vừa có thể dùng để trích xuất đặc trưng vừa có thể trực quan dữ liệu.


Spectrogram được tạo ra bằng cách áp dụng Biến đổi Fourier Ngắn Hạn (STFT) lên tín hiệu âm thanh.

Biểu đồ của spectrogram của người thứ 1, cảm xúc bình thản:



Hình 3.6: Biểu đồ Spectrogram của diễn thứ thứ nhất, cảm xúc bình thản.

Thông qua biểu đồ spectrogram, ta có thể nhận thấy rằng âm thanh tập trung chủ yếu trong khoảng 1 giây đầu tiên và giây thứ 2.5. Đây là những đoạn tín hiệu nổi bật với tần số dao động cao, từ 64 Hz đến 4096 Hz, đồng thời mức cường độ âm nằm trong khoảng -0 dB đến -60 dB, cho thấy âm thanh tại đây có sự hiện diện mạnh mẽ và rõ ràng. Trong khi đó, các vùng khác trên biểu đồ có xu hướng yếu hơn hoặc ít thông tin hơn, thể hiện các đoạn tín hiệu tĩnh hoặc kém nổi bật.




Hình 3.7: Biểu đồ Spectrogram của diễn viên thứ nhất, tám cảm xúc khác nhau.

Tần số phân bố các đều ở các đơn vị thời gian trung tâm, có âm lượng từ -10dB đến -60dB và tần số từ 0Hz đến 4096 Hz. Tuy nhiên ta vẫn có thể thấy từ các giây đầu và cuối không có đoạn nhỏ không có tín hiệu tần số và không có tín hiệu và cường độ âm thanh.

d. Zero-Crossing-Rate (ZCR):

ZCR đo lường tần suất mà tín hiệu âm thanh chuyển từ giá trị dương sang âm (hoặc ngược lại) trong một khung tín hiệu nhất định.


Biểu đồ cho file âm thanh đầu tiên:




Hình 3.8: Biểu đồ ZCR của diễn viên thứ nhất, cảm xúc bình thản.

Đường waveform – màu xanh là tín hiệu của giọng nói. Đường ZCR – màu vàng diễn tả sự biến thiên của tín hiệu. Đường ZCR càng nhấp nhô cao thì tín hiệu càng ổn định (không có âm thanh), ngược lại tín hiệu có sự thay đổi, biểu trưng của giọng nói. Từ đó có thể thấy đoạn có thông tin dồi dào nhất là đoạn từ 1s đến 2.5s. các đoạn còn lại các tín hiệu rất yếu hoặc không có âm thanh.

Tiếp tục cho các đoạn âm thanh tiếp theo:





Hình 3.9: Biểu của ZCR của diễn viên thứ nhất, tám cảm xúc khác nhau.


Tương tự các cách trích xuất khác, dễ để thấy âm thanh phân bố ở đoạn giữa, biên độ không cao chứng tỏ đây là nam. Nhưng vẫn khó có thể thấy rõ đặc trưng cảm xúc thông qua các trích xuất này.

e. Spectral features:

Các loại Spectral Features phổ biến: tâm phổ, độ rộng phổ, độ tương phản phổ, độ phẳng phổ.

Spectral Centroid (Tâm phổ):

Là giá trị trung bình có trọng số của tần số, cho biết "tâm" năng lượng của phổ tần số nằm ở đâu.




Hình 3.10: Biểu đồ tâm phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau.

Tâm phổ thấp: Âm thanh trầm, thường là tiếng bass hoặc giọng nói thấp. Tâm phổ cao: Âm thanh sắc, chói, hoặc tiếng ồn tần số cao. Biểu đồ này có 1 số giai đoạn tâm phổ khá thấp 2000-3000, cho thấy người đang nói có giọng trầm có thể tùy vào cảm xúc, các cảm xúc tích sẽ cho tâm phổ cao hơn là các cảm xúc tiêu cực. Và các đoạn còn lại là trung bình cao ở biên có thể do nhiễu.

Spectral Bandwidth (Độ rộng phổ):

Là độ lệch chuẩn của phổ tần số xung quanh Spectral Centroid.

Biểu đồ độ rộng phổ file thứ nhất:




Hình 3.11: Biểu đồ độ rộng phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau.

Độ rộng phổ lớn: Tín hiệu có nhiều thành phần tần số, như nhạc cụ phức tạp hoặc tiếng ồn. Độ rộng phổ nhỏ: Tín hiệu thuần túy, như tiếng nhạc cụ đơn giản hoặc giọng nói nhẹ nhàng.

Spectral Contrast (Độ tương phản phổ):

Là sự khác biệt năng lượng giữa các đỉnh và đáy của phổ tần số.




Hình 3.12: Biểu đồ độ tương phản phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau.

Khi các đường cao ở trên thì tín hiệu có độ động lớn, thường thấy trong âm nhạc phức tạp còn thấp thì âm thanh mượt mà hoặc bị nén nhiều. Tần số của tín hiệu khá thấp cho thấy âm thanh khá êm.

Có một vài đoạn có độ tương phản cao, còn cái đoạn còn lại thấp. Cho thấy âm thanh ngoài tiếng người nói còn có thể có tiếng đoạn khá phức tạp.

Spectral Flatness (Độ phẳng phổ):

Đánh giá mức độ "phẳng" của phổ tần số, so sánh giữa năng lượng trung bình và năng lượng đỉnh.



Hình 3.13: Biểu đồ độ phẳng phổ của diễn viên thứ nhất, với tám cảm xúc khác nhau.

Khi đường cao thì tín hiệu ồn, như tiếng trắng (white noise), thấp thì tín hiệu cấu trúc rõ ràng, như giọng nói hoặc nhạc cụ. Tín hiệu hầu như không có tạp âm, khá ổn định và hoàn chỉnh tiếng người nói.

4) Tiền xử lý dữ liệu:

Chuẩn hóa: Quá trình này đưa các đặc trưng về cùng một phạm vi giá trị (thường là $[0, 1]$ hoặc $\text{mean}=0$, $\text{std}=1$) để loại bỏ ảnh hưởng của các đặc trưng có phạm vi lớn (như Spectral Centroid tính bằng Hz) lên mô hình học máy. Phương thức phổ biến là Min-Max Scaling, trong đó giá trị được điều chỉnh dựa trên giá trị tối thiểu và tối đa của từng đặc trưng, hoặc Standard Scaling, sử dụng trung bình và độ lệch chuẩn để chuẩn hóa dữ liệu.

Làm mịn: Mục tiêu là giảm nhiễu hoặc dao động không mong muốn trong các đặc trưng, đặc biệt với Spectral Centroid hoặc Spectral Flatness khi có đoạn nhiễu (như file 1 ở giây 0). Phương thức thường dùng là bộ lọc trung bình động (moving average), tính giá trị trung bình trên một cửa sổ thời gian trượt, hoặc bộ lọc Gaussian, áp dụng phân phối Gaussian để làm mịn dữ liệu, giúp giữ được xu hướng tổng thể mà giảm thiểu biến động cục bộ.

Đồng bộ hóa độ dài: Vì các file âm thanh có độ dài khác nhau, dẫn đến số khung (frame) của các đặc trưng không đồng nhất, bước này đảm bảo tất cả đặc trưng có cùng số lượng điểm dữ liệu. Phương thức thực hiện bao gồm cắt hoặc đệm (truncate/pad) để đưa dữ liệu về một độ dài cố định (thường là độ dài nhỏ nhất hoặc một giá trị tối đa đã chọn),

hoặc sử dụng nội suy tuyến tính (linear interpolation) để điều chỉnh số khung phù hợp với độ dài mục tiêu, giúp dễ dàng so sánh hoặc sử dụng trong mô hình.

Giảm chiều: Mục đích là giảm số lượng biến số để cải thiện hiệu suất tính toán và tránh overfitting, đặc biệt với đặc trưng như Spectral Contrast có nhiều dải tần số. Phương thức phổ biến là phân tích thành phần chính (PCA), giữ lại các thành phần chính chứa phần lớn thông tin, hoặc tính trung bình theo các đoạn (segment averaging) để tổng hợp dữ liệu thành các vector đại diện, giúp đơn giản hóa dữ liệu mà vẫn giữ được đặc điểm chính.

5) Chuẩn bị dữ liệu cho học máy:

Kiểm tra xem kiểu dữ liệu, chiều dữ liệu có phù hợp với mô hình hay chưa. Nếu chưa sử dụng các phương pháp trên để đưa dữ liệu về cho phù hợp với mô hình.

II. Nguyên lý hoạt động của mô hình:

Ở báo cáo này, chúng tôi sẽ giới thiệu và sử dụng 5 mô hình cơ bản là Random Forest, Support Vector Machine, XGBoost, Voting Ensemble.

1) Random Forest:

Random Forest là một thuật toán học máy thuộc nhóm ensemble (tập hợp), dựa trên bagging (Bootstrap Aggregating) và sử dụng nhiều cây quyết định (decision trees) để đưa ra dự đoán.

Bước 1: Tạo dữ liệu con (Bootstrap Sampling): Từ tập dữ liệu gốc, Random Forest tạo ra nhiều tập dữ liệu con (bootstrap samples) bằng cách lấy mẫu ngẫu nhiên có lặp lại (with replacement). Điều này có nghĩa một mẫu có thể được chọn nhiều lần trong cùng một tập con. Mỗi tập dữ liệu con có kích thước bằng tập dữ liệu gốc, nhưng do lấy mẫu ngẫu nhiên, khoảng 63% dữ liệu gốc được sử dụng trong mỗi tập con (các mẫu còn lại gọi là out-of-bag và được dùng để đánh giá mô hình).

Bước 2: Xây dựng nhiều cây quyết định: Với mỗi tập dữ liệu con, một cây quyết định được xây dựng. Tuy nhiên, để tăng tính ngẫu nhiên và giảm sự tương quan giữa các cây:

Tại mỗi nút của cây, thay vì xem xét tất cả các đặc trưng (features), Random Forest chỉ chọn ngẫu nhiên một tập hợp con của các đặc trưng (thường là $\sqrt{n_features}$) cho phân loại hoặc $n_features/3$ cho hồi quy).

Cây được xây dựng đến độ sâu tối đa (hoặc không giới hạn) mà không cắt tỉa (pruning), dẫn đến các cây có độ phức tạp cao.

Bước 3: Kết hợp dự đoán (Aggregation): Đối với bài toán phân loại: Mỗi cây đưa ra một dự đoán (vote), và Random Forest chọn lớp có số phiếu cao nhất (majority voting). Đối với bài toán hồi quy: Kết quả cuối cùng là trung bình của các dự đoán từ tất cả các cây.

Out-of-bag error được tính từ các mẫu không được sử dụng trong quá trình huấn luyện mỗi cây để đánh giá hiệu suất mà không cần tập kiểm tra riêng.

2) SVM (Support Vector Machine)

SVM là một thuật toán học máy giám sát, tìm cách xây dựng một siêu phẳng (hyperplane) tối ưu để phân tách các lớp dữ liệu trong không gian đặc trưng.

Bước 1: Tìm siêu phẳng phân tách: Trong không gian đặc trưng (có thể là 2D, 3D hoặc nhiều chiều hơn), SVM tìm một siêu phẳng sao cho khoảng cách (margin) giữa siêu phẳng và các điểm dữ liệu gần nhất của mỗi lớp (gọi là support vectors) là lớn nhất. Đây gọi là maximum margin hyperplane.

Công thức: Siêu phẳng được định nghĩa bởi phương trình $w^T x + b = 0$, trong đó w là vector pháp tuyến, b là độ lệch (bias), và x là điểm dữ liệu.

Bước 2: Tối ưu hóa margin: SVM giải bài toán tối ưu hóa để tối đa hóa margin, tức là tối đa hóa $\|w\|$ (khoảng cách margin tỷ lệ nghịch với độ dài của w).

Điều kiện ràng buộc: $y_i(w^T x_i + b) \geq 1$ cho tất cả các điểm dữ liệu, trong đó y_i là nhãn lớp (+1 hoặc -1).

Bước 3: Sử dụng Soft Margin (cho dữ liệu không phân tách tuyến tính được): Trong thực tế, dữ liệu thường không phân tách tuyến tính hoàn hảo. SVM đưa vào soft margin, cho phép một số điểm dữ liệu nằm sai phía của siêu phẳng bằng cách thêm biến slack variables (ξ_i). Hàm mất mát trở thành: $\min (1/2 \|w\|^2 + C * \sum \xi_i)$, trong đó C là tham số điều chỉnh mức độ phạt các lỗi phân loại.

Bước 4: Kernel Trick (cho dữ liệu không tuyến tính):

Khi dữ liệu không thể phân tách tuyến tính trong không gian ban đầu, SVM sử dụng kernel trick để ánh xạ dữ liệu lên không gian chiều cao hơn, nơi dữ liệu có thể phân tách tuyến tính.

Các kernel phổ biến:

Linear Kernel: $K(x, x') = x^T x'$.

Polynomial Kernel: $K(x, x') = (x^T x' + 1)^d$.

RBF (Gaussian) Kernel: $K(x, x') = \exp(-\|x - x'\|^2 / (2\sigma^2))$.

Kernel giúp tính toán trong không gian chiều cao mà không cần ánh xạ trực tiếp, tiết kiệm tài nguyên.

Bước 5: Dự đoán: Với một điểm dữ liệu mới, SVM tính toán vị trí của điểm đó so với siêu phẳng và dự đoán lớp dựa trên dấu của $w^T x + b$.

3) Voting Ensemble

Voting Ensemble là một kỹ thuật ensemble kết hợp dự đoán từ nhiều mô hình khác nhau (có thể là Random Forest, SVM, Logistic Regression, v.v.) để đưa ra kết quả cuối cùng.

Bước 1: Xây dựng các mô hình cơ sở (Base Models): Chọn nhiều mô hình khác nhau (hoặc cùng loại nhưng với các tham số khác nhau) để huấn luyện trên tập dữ liệu. Ví dụ: một Random Forest, một SVM, và một mô hình hồi quy logistic.

Mỗi mô hình được huấn luyện độc lập trên toàn bộ tập dữ liệu hoặc các tập dữ liệu con.

Bước 2: Thu thập dự đoán từ các mô hình:

Đối với mỗi điểm dữ liệu, mỗi mô hình cơ sở đưa ra một dự đoán:

Phân loại: Dự đoán lớp (ví dụ: 0 hoặc 1).

Hồi quy: Dự đoán giá trị liên tục.

Bước 3: Kết hợp dự đoán (Voting):

Có hai phương thức chính:

Hard Voting (Bỏ phiếu đa số):

Mỗi mô hình "bỏ phiếu" cho một lớp, và lớp có số phiếu cao nhất được chọn.

Ví dụ: Nếu 3 mô hình dự đoán $[1, 0, 1]$, lớp 1 được chọn (2 phiếu).

Soft Voting (Bỏ phiếu dựa trên xác suất):

Mỗi mô hình đưa ra xác suất thuộc về từng lớp, và Voting Ensemble tính trung bình xác suất của tất cả mô hình, sau đó chọn lớp có xác suất trung bình cao nhất.

Ví dụ: Mô hình 1: $[0.9, 0.1]$, mô hình 2: $[0.6, 0.4]$, trung bình: $[0.75, 0.25] \rightarrow$ chọn lớp 1.

Bước 4: Đưa ra kết quả: Kết quả cuối cùng là kết quả của quá trình bỏ phiếu (hard hoặc soft), thường chính xác hơn từng mô hình đơn lẻ nhờ tận dụng sự đa dạng của các mô hình cơ sở.

4) XGBoost (Extreme Gradient Boosting)

XGBoost là một thuật toán gradient boosting nâng cao, sử dụng cây quyết định làm mô hình cơ sở và tối ưu hóa hiệu suất bằng cách áp dụng các kỹ thuật như regularization và parallel processing.

Bước 1: Khởi tạo mô hình: Bắt đầu với một dự đoán ban đầu (thường là trung bình của các giá trị mục tiêu trong bài toán hồi quy, hoặc log-odds trong phân loại).

Bước 2: Xây dựng các cây quyết định tuần tự: XGBoost xây dựng các cây quyết định một cách tuần tự (sequentially), mỗi cây cố gắng sửa lỗi của các cây trước đó.

Tại mỗi bước:

Tính gradient (đạo hàm) và hessian (đạo hàm bậc hai) của hàm mất mát so với dự đoán hiện tại để xác định hướng và mức độ điều chỉnh.

Cây quyết định được xây dựng để dự đoán residuals (sai số giữa giá trị thực và dự đoán hiện tại).

Bước 3: Tối ưu hóa hàm mất mát: XGBoost sử dụng hàm mất mát tùy chỉnh (ví dụ: MSE cho hồi quy, log-loss cho phân loại) và thêm các thành phần regularization:

L1 (Lasso) và L2 (Ridge) regularization trên trọng số của các lá (leaf weights). Penalty cho số lượng lá và độ phức tạp của cây.

Công thức tổng quát: $\text{Objective} = \text{Loss} + \Omega$, trong đó Ω là regularization term.

Bước 4: Cập nhật dự đoán: Mỗi cây mới được nhân với một learning rate (thường nhỏ, như 0.1) để tránh cập nhật quá mạnh, sau đó cộng vào dự đoán hiện tại:

$\text{prediction} = \text{prediction} + \text{learning_rate} * \text{tree_output}$.

Bước 5: Lặp lại và kết hợp: Quá trình được lặp lại cho đến khi đạt số cây tối đa hoặc hàm mất mát không cải thiện thêm.

Kết quả cuối cùng là tổng của tất cả các cây (được nhân với learning rate).

Các kỹ thuật tối ưu hóa của XGBoost:

Parallelization: Xây dựng các cây song song trên các đặc trưng, tăng tốc độ huấn luyện.

Handling Missing Values: Tự động xử lý giá trị thiếu bằng cách tìm hướng tối ưu cho các giá trị thiếu.

Tree Pruning: Sử dụng chiến lược "post-pruning" dựa trên thông số max_depth và gamma để kiểm soát độ phức tạp.

Weighted Quantile Sketch: Chia các đặc trưng thành các bucket để tìm điểm phân chia tối ưu nhanh hơn.

III. Cài đặt mô hình:

1) Định nghĩa các mô hình:

```
118 rf = RandomForestClassifier(  
119     n_estimators=100,  
120     max_depth=None,  
121     min_samples_split=2,  
122     random_state=42  
123 )  
124 xgb = XGBClassifier(  
125     n_estimators=100,  
126     learning_rate=0.1,  
127     max_depth=3,  
128     random_state=42,  
129     use_label_encoder=False,  
130     eval_metric='mlogloss'  
131 )  
132 svm = SVC(  
133     C=1.0,  
134     kernel='rbf',  
135     gamma='scale',  
136     probability=True,  
137     random_state=42  
138 )
```

2) Ý nghĩa các tham số:

Random Forest:

n_estimators: Số lượng cây quyết định trong rừng (100, 300, 500). Giá trị càng lớn, mô hình càng phức tạp nhưng có thể dẫn đến overfitting.

max_depth: Độ sâu tối đa của mỗi cây (10, 20, 30). Điều chỉnh độ phức tạp của từng cây.

min_samples_split: Số lượng mẫu tối thiểu để chia một nút (2, 5, 10). Giúp kiểm soát overfitting bằng cách yêu cầu đủ dữ liệu để chia.

XGBoost:

n_estimators: Số lượng bộ tăng cường (boosters) (100, 300, 500). Tương tự như Random Forest, ảnh hưởng đến độ phức tạp.

max_depth: Độ sâu tối đa của mỗi cây (3, 5, 10). Điều chỉnh độ chi tiết của mô hình.

learning_rate: Tốc độ học (0.01, 0.05, 0.1). Quyết định mức độ đóng góp của mỗi bộ tăng cường, giá trị nhỏ thường cần nhiều estimators hơn.

eval_metric: hàm đánh giá.

SVM (Support Vector Machine):

C: Hệ số phạt cho sai số (0.1, 1, 10, 100). Giá trị lớn hơn làm mô hình ít dung sai hơn với sai số.

gamma: Hệ số kernel (0.001, 0.01, 0.1). Ảnh hưởng đến độ cong của ranh giới quyết định, giá trị lớn hơn tạo ranh giới phức tạp hơn.

kernel: Loại kernel sử dụng ('rbf'). Trong trường hợp này, chỉ dùng kernel RBF (Radial Basis Function).

IV. Tiêu chí đánh giá mô hình:

1) Accuracy (độ chính xác):

Độ chính xác là một thước đo tổng quát về hiệu suất của mô hình. Nó đánh giá tỷ lệ số lượng dự đoán mà mô hình đưa ra là chính xác so với tổng số lượng các dự đoán đã thực hiện trên tập dữ liệu đánh giá. Một độ chính xác cao cho thấy mô hình dự đoán đúng phần lớn các trường hợp. Tuy nhiên, độ chính xác có thể gây hiểu lầm trong các bài toán phân loại có sự mất cân bằng lớn giữa các lớp (ví dụ, một lớp chiếm đa số lượng mẫu). Trong những trường hợp như vậy, một mô hình đơn giản chỉ dự đoán theo lớp đa số vẫn có thể đạt được độ chính xác cao mà không thực sự học được cách phân loại các lớp thiểu số.

$$\text{Công thức: } Acc = \frac{\text{Số lượng mẫu đoán đúng}}{\text{Tổng mẫu}}$$

2) Precision (Độ chính xác):

Precision đo lường trong số tất cả các mẫu mà mô hình dự đoán là thuộc về một lớp cụ thể, có bao nhiêu mẫu thực sự thuộc về lớp đó. Nó tập trung vào tính chính xác của các

dự đoán dương tính. Precision cao có nghĩa là khi mô hình dự đoán một mẫu là dương tính cho một lớp, thì khả năng cao là dự đoán đó đúng. Precision thấp có thể chỉ ra rằng mô hình đang tạo ra nhiều dương tính giả (dự đoán sai là dương tính).

Công thức (cho một lớp cụ thể): $Precision = \frac{TP}{TP+FP}$

Trong đó:

TP (True Positives): Số lượng mẫu thực tế thuộc lớp đó và được mô hình dự đoán đúng là thuộc lớp đó.

FP (False Positives): Số lượng mẫu thực tế không thuộc lớp đó nhưng bị mô hình dự đoán nhầm là thuộc lớp đó.

3) Recall (Độ phủ/Độ nhạy):

Recall đo lường trong số tất cả các mẫu thực tế thuộc về một lớp cụ thể, mô hình đã nhận diện đúng được bao nhiêu mẫu. Nó tập trung vào khả năng của mô hình trong việc tìm ra tất cả các mẫu dương tính thực tế. Recall cao có nghĩa là mô hình ít bỏ sót các mẫu dương tính thực tế. Recall thấp có thể chỉ ra rằng mô hình không nhận diện được nhiều mẫu dương tính thực tế (tạo ra nhiều âm tính giả).

Công thức (cho một lớp cụ thể): $Recall = \frac{TP}{TP+FN}$

Trong đó:

FN (False Negatives): Số lượng mẫu thực tế thuộc lớp đó nhưng bị mô hình dự đoán nhầm là không thuộc lớp đó.

4) F1-score:

F1-score là trung bình điều hòa của precision và recall. Nó cung cấp một thước đo duy nhất cân bằng giữa precision và recall. F1-score đặc biệt hữu ích khi có sự mất cân bằng giữa precision và recall. Một F1-score cao cho thấy mô hình có cả precision và recall tốt cho lớp đó.

Công thức: $F1 = 2 * \frac{Precision * Recall}{Precision + Recall}$

5) Macro Average:

Macro average tính trung bình cộng của các chỉ số (precision, recall, f1-score) trên tất cả các lớp. Mỗi lớp được coi là có trọng số bằng nhau trong phép tính trung bình. Macro average hữu ích khi bạn muốn đánh giá hiệu suất trung bình của mô hình trên tất cả các nhãn một cách đồng đều, không bị ảnh hưởng bởi sự khác biệt về số lượng mẫu giữa các lớp. Nó cho biết hiệu suất tổng thể của mô hình trên tất cả các lớp, giả sử tất cả các lớp đều quan trọng như nhau.

Công thức: $MAP = \frac{1}{n} \sum_{i=1}^n Precision_i$

Trong đó, n là số lượng lớp. Công thức tương tự áp dụng cho Recall và F1-score Macro Average.

6) Weighted Average:

Weighted average tính trung bình có trọng số của các chỉ số (precision, recall, f1-score) trên tất cả các lớp. Trọng số của mỗi lớp tỷ lệ với số lượng mẫu thực tế thuộc về lớp đó (support). Weighted average cung cấp một cái nhìn tổng quan về hiệu suất của mô hình trên toàn bộ tập dữ liệu, có tính đến sự mất cân bằng lớp. Các lớp có số lượng mẫu lớn hơn sẽ có ảnh hưởng lớn hơn đến giá trị trung bình. Đây thường là một thước đo hữu ích hơn so với macro average khi các lớp có sự chênh lệch lớn về kích thước, vì nó phản ánh hiệu suất của mô hình trên các lớp phổ biến hơn.

Công thức:
$$\frac{\sum_{i=1}^n (Precision_i * Support_i)}{\sum_{i=1}^n Support_i}$$

CHƯƠNG 4: THỰC NGHIỆM

I. Yêu cầu về chương trình:

1) Cấu hình:

CPU Intel Xeon hoặc tương đương, 2 lõi (dual-core) với tốc độ ~2.2 GHz.

RAM: Khoảng 10-11GB.

Ổ cứng: Khoảng 70-80GB dung lượng tạm thời (temporary disk).

GPU: NVIDIA Tesla T4 (16GB VRAM) hoặc K80 (12GB VRAM)

2) Chương trình: Python

Phiên bản: 3.11

3) Thư viện:

Dòng Import	Thư viện	Phiên bản
import os	os	Đi kèm với Python 3.11
import pandas as pd	pandas	2.2.2
import numpy as np	numpy	1.26.4
import librosa	librosa	0.10.1
from scipy.signal import butter, lfilter	scipy.signal	1.13.0
from sklearn.preprocessing import StandardScaler, LabelEncoder	scikit-learn	1.5.0
from sklearn.model_selection import train_test_split, GridSearchCV	scikit-learn	1.5.0
from sklearn.ensemble import RandomForestClassifier, VotingClassifier	scikit-learn	1.5.0
from sklearn.svm import SVC	scikit-learn	1.5.0
from sklearn.metrics import accuracy_score, classification_report	scikit-learn	1.5.0
from xgboost import XGBClassifier	xgboost	2.0.3
from imblearn.over_sampling import SMOTE	imbalanced-learn	0.12.2
from scipy.stats import skew, kurtosis	scipy.stats	1.13.0
import gc	gc	Đi kèm với Python 3.11
import seaborn as sns	seaborn	0.13.2
import matplotlib.pyplot as plt	matplotlib.pyplot	3.8.3

II. Cài đặt:

1) Nhập dữ liệu:

```
23 data_dir = "/kaggle/input/ravdess-emotional-speech-audio"
24
25 emotion_map = {
26     "01": (0, "neutral"), "02": (1, "calm"), "03": (2, "happy"), "04": (3, "sad"),
27     "05": (4, "angry"), "06": (5, "fearful"), "07": (6, "disgust"), "08": (7, "surprised")
28 }
29
30 data = []
31 for actor_dir in os.listdir(data_dir):
32     actor_path = os.path.join(data_dir, actor_dir)
33     if os.path.isdir(actor_path):
34         for file in os.listdir(actor_path):
35             if file.endswith(".wav"):
36                 parts = file.split("-")
37                 emotion_code = parts[2]
38                 emotion_idx = emotion_map.get(emotion_code, (-1, "unknown"))[0]
39                 file_path = os.path.join(actor_path, file)
40                 data.append({"file_path": file_path, "emotion": emotion_idx})
41 df = pd.DataFrame(data)
```

Dòng 23: Lấy đường dẫn của tập dữ liệu từ link kaggle.

Dòng 24-28: Tạo từ điển ánh xạ cảm xúc dạng số sang dạng số và chuỗi.

Vòng for lặp qua các thư mục của từng diễn viên trong thư mục dữ liệu. Tạo đường dẫn tuyệt đối đến thư mục diễn viên. Nếu đường dẫn đó là thư mục thì duyệt qua tất cả các file trong thư mục diễn viên. Lấy ra các file có đuôi .wav, tiến hành tách theo dấu "-" để lấy ra từng phần, lấy cảm xúc ở phần thứ 3 (nếu không có trả về -1), tạo đường dẫn trực tiếp đến file.wav đó và cuối cùng thêm đường dẫn file và cảm xúc vào mảng data đã khởi tạo trước đó.

4) Biến đổi dữ liệu:

```
76 df['data_raw'] = None
77 for idx, row in df.iterrows():
78     audio, sr = librosa.load(row['file_path'], sr=48000)
79     df.at[idx, 'data_raw'] = audio
```

Biến đổi âm thanh dạng sóng thông qua địa chỉ trực tiếp thành dạng mảng và thêm vào cột 'data_raw'.

5) Cắt:

```

1 import numpy as np
2 import librosa
3
4 def remove_silence(audio, sr, frame_length=2048, hop_length=512, top_db=30):
5     intervals = librosa.effects.split(audio, top_db=top_db, frame_length=frame_length, hop_length=hop_length)
6     audio_clean = np.concatenate([audio[start:end] for start, end in intervals])
7     return audio_clean
8 df['data_raw_clean'] = df['data_raw'].apply(lambda x: remove_silence(x, sr=16000))

```

Sử dụng thư viện librosa để cắt các đoạn âm thanh có dưới 30 (top_dB) và sau đó nối các mảng đã được cắt ra và lưu vào data_raw_clean. Thời lượng âm thanh sẽ giảm đi một nửa, vì đoạn đầu và đoạn cuối hầu như không có âm thanh.

6) Lọc nhiễu:

```

45 def denoise_audio(audio, sr=48000, cutoff=3500, order=5):
46     nyquist = 0.5 * sr
47     normal_cutoff = cutoff / nyquist
48     b, a = butter(order, normal_cutoff, btype='low', analog=False)
49     return lfilter(b, a, audio)

```

Lọc những âm thông thấp, đơn giản có thể hiểu hàm sẽ loại bỏ những âm có tần số cao hơn 3500 (cutoff).

7) Kéo giãn thời gian:

```

1 def stretch(data, rate=1):
2     return librosa.effects.time_stretch(y=data, rate=rate)
3
4 df['data_raw_time'] = df['data_raw_butter'].apply(lambda x: stretch(x, rate=1))

```

Sử dụng thư viện librosa để kéo giãn thời gian, với rate = 1, thời gian giữ nguyên; rate < 1: âm thanh sẽ chậm lại, rate > 1: âm thanh sẽ nhanh hơn. Và lưu vào cột 'data_raw_time'

8) Trích xuất đặc trưng:

Như đã nói ở báo cáo này sẽ sử dụng cách trích xuất MFCCs để tiến hành nhận diện cảm xúc.

```

1 import librosa
2
3 def extract_mfcc(audio, sr=48000, n_mfcc=13):
4     mfcc = librosa.feature.mfcc(y=audio, sr=sr, n_mfcc=n_mfcc)
5     return mfcc
6
7 df['mfcc'] = df['data_raw_time'].apply(lambda x: extract_mfcc(x))

```

Sử dụng thư viện librosa để trích xuất đặc trưng. Và lưu vào cột 'mfcc'.

9) Làm mịn:

```

1 from scipy.signal import savgol_filter
2
3 def smooth_audio(audio, window_length=11, polyorder=2):
4     audio_smoothed = savgol_filter(audio, window_length, polyorder)
5     return audio_smoothed

```

window_length: Độ dài của sổ trượt (số điểm lấy mẫu trong mỗi cửa sổ). Nó phải là số lẻ và lớn hơn polyorder. **polyorder:** Bậc đa thức dùng để xấp xỉ dữ liệu trong cửa sổ trượt.

Sử dụng bộ lọc savgol_filter để tiến hành làm mịn.

10) Chuẩn hóa:

```

1 def normalize_mfcc(mfcc):
2     scaler = StandardScaler()
3     return scaler.fit_transform(mfcc.T).T

```

Sử dụng hàm StandardScaler để tự động chuẩn hóa. Trong đó ở dòng return .T đầu tiên là đưa ma trận (13, x) về (x, 13) để thực hiện chuẩn hóa và .T thứ hai là chuyển ma trận đã chuẩn hóa về dạng ban đầu tức (13, x).

11) Padding:

```

1 def pad_mfcc(mfcc):
2     return fix_length(mfcc, size=2048, axis=1)
3

```

Điều chỉnh độ dài của chiều thứ hai trong mfcc (13, x) thành chiều dài có định 2048 (size).

Sau khi thực hiện các bước xử lý dữ liệu, ta có thể kéo mảng mfcc (2 chiều) ra thành mảng 1 chiều và phân chia dữ liệu train, test để đưa vào mô hình học máy.

```

11 X_train, X_test, y_train, y_test = train_test_split(
12     X, y, test_size=0.2, random_state=42,
13 )

```

Với train là 80%, và test là 20%.

CHƯƠNG 5: KẾT QUẢ:

I. Kết quả khai phá:

=== Huấn luyện mô hình: Random Forest ===

Độ chính xác: 0.4618

Báo cáo phân loại:

	precision	recall	f1-score	support
neutral_calm	0.51	0.81	0.63	59
happy_intensity_1	0.50	0.20	0.28	41
sad_intensity_1	0.46	0.17	0.25	35
angry_intensity_1	0.41	0.53	0.46	34
fearful_intensity_1	0.35	0.42	0.38	31
disgust_intensity_1	0.59	0.49	0.54	45
surprised_intensity_1	0.38	0.42	0.40	43
accuracy			0.46	288
macro avg	0.46	0.43	0.42	288
weighted avg	0.47	0.46	0.44	288

=== Huấn luyện mô hình: KNN ===

Độ chính xác: 0.3958

Báo cáo phân loại:

	precision	recall	f1-score	support
neutral_calm	0.40	0.81	0.54	59
happy_intensity_1	0.35	0.32	0.33	41
sad_intensity_1	0.24	0.14	0.18	35
angry_intensity_1	0.36	0.47	0.41	34
fearful_intensity_1	0.48	0.35	0.41	31
disgust_intensity_1	0.62	0.29	0.39	45
surprised_intensity_1	0.38	0.19	0.25	43
accuracy			0.40	288
macro avg	0.40	0.37	0.36	288
weighted avg	0.41	0.40	0.37	288

=== Huấn luyện mô hình: SVM ===

Độ chính xác: 0.4826

Báo cáo phân loại:

	precision	recall	f1-score	support
neutral_calm	0.54	0.80	0.64	59
happy_intensity_1	0.52	0.29	0.38	41
sad_intensity_1	0.40	0.23	0.29	35
angry_intensity_1	0.48	0.59	0.53	34
fearful_intensity_1	0.32	0.52	0.40	31
disgust_intensity_1	0.56	0.49	0.52	45
surprised_intensity_1	0.52	0.33	0.40	43
accuracy			0.48	288
macro avg	0.48	0.46	0.45	288
weighted avg	0.49	0.48	0.47	288

Vì kết quả của Random Forest và SVM không khả thi, nên khả năng cao Voting Ensemble và XGBoost cũng không cao nên ở đây chúng tôi đã thử sử dụng KNN với $k = 10$ để xem khả năng phân bố của dữ liệu đã trích xuất có tốt hay chưa. Và kết quả cho thấy, các dữ liệu lân cận điểm đang xét, không đồng nhất.

Kết quả thực nghiệm cho thấy độ chính xác đạt được lần lượt là 0.4618 cho RF, 0.3958 cho KNN và 0.4826 cho SVM, rất thấp so với dự đoán ban đầu. Kết quả < 0.5 mô hình dự đoán sai hầu hết các mẫu, chứng tỏ mô hình đang không hiểu được cách hoạt động của dữ liệu âm thanh cảm xúc.

Các con số kết quả không được khả quan có thể do cách trích xuất đặc trưng không đủ để lấy toàn bộ thông tin cảm xúc. Hoặc các bước tiền xử lý làm ảnh hưởng đến thông tin.

II. So sánh với kết quả thực tế:

Dữ liệu có thể bị mất đi thông tin thông qua các cách tiền lý, làm cho mô hình có kết quả quá thấp so với kết quả dự đoán ban đầu là 80%.

Nguyên lý hoạt động về mặt lý thuyết có thể giải quyết được bài toán, nhưng có lẽ dữ liệu không đủ phong phú nên mô hình cho ra kết quả phân loại thấp trên tất cả các nhãn cảm xúc.

CHƯƠNG 6: TÍNH CHỈNH:

I. Thay đổi cách xử lý dữ liệu:

Bỏ các bước tiền xử lý có thể ảnh hưởng đến dữ liệu:

Padding, cắt, làm mịn: các bước làm ảnh hưởng đến những khoảng nghỉ trong giọng nói có thể làm mất đi những thông tin quan trọng.

Thêm nhiễu nhẹ, thay đổi cao độ, điều chỉnh tham số kéo giãn thời gian.

```
def augment_audio(audio, sr=48000):
    augmented = []
    augmented.append(audio + 0.001 * np.random.randn(len(audio)))
    augmented.append(librosa.effects.pitch_shift(audio, sr=sr, n_steps=1))
    augmented.append(librosa.effects.time_stretch(audio, rate=1.1))
    return augmented
```

Trích xuất đặc trưng: thay vì MFCC, bây giờ sử dụng gộp 6 các trích xuất gồm: MFCC, delta MFCC, delta-delta MFCC, Chroma, spectral contrast, tonnetz.

Trong đó delta MFCC và delta-delta MFCC là trích xuất nâng cao của MFCC và tonnetz là trích xuất nâng cao của Chroma.

```
60 def extract_features(audio, sr=48000, n_mfcc=40):
61
62     audio = audio / np.max(np.abs(audio))
63     mfcc = librosa.feature.mfcc(y=audio, sr=sr, n_mfcc=n_mfcc, n_fft=1024, hop_length=256)
64     delta_mfcc = librosa.feature.delta(mfcc)
65     delta_delta_mfcc = librosa.feature.delta(mfcc, order=2)
66     chroma = librosa.feature.chroma_stft(y=audio, sr=sr)
67     contrast = librosa.feature.spectral_contrast(y=audio, sr=sr)
68     tonnetz = librosa.feature.tonnetz(y=audio, sr=sr)
69
70     mfcc_stats = np.concatenate([np.mean(mfcc, axis=1), np.std(mfcc, axis=1),
71                                skew(mfcc, axis=1), kurtosis(mfcc, axis=1)])
72     delta_stats = np.concatenate([np.mean(delta_mfcc, axis=1), np.std(delta_mfcc, axis=1)])
73     delta_delta_stats = np.concatenate([np.mean(delta_delta_mfcc, axis=1), np.std(delta_delta_mfcc, axis=1)])
74     chroma_stats = np.concatenate([np.mean(chroma, axis=1), np.std(chroma, axis=1)])
75     contrast_stats = np.concatenate([np.mean(contrast, axis=1), np.std(contrast, axis=1)])
76     tonnetz_stats = np.concatenate([np.mean(tonnetz, axis=1), np.std(tonnetz, axis=1)])
77
78     return np.concatenate([mfcc_stats, delta_stats, delta_delta_stats, chroma_stats, contrast_stats, tonnetz_stats])
```

Sau đó tiến hành tính thống kê và gộp vào mảng.

Áp dụng SMOTE để cân bằng lớp.

```
106 smote = SMOTE(random_state=42)
107 X_balanced, y_balanced = smote.fit_resample(X, y)
```

Chia lại dữ liệu;

```
115 X_train, X_test, y_train, y_test = train_test_split(X_balanced, y_balanced, test_size=0.2, random_state=42)
```

II. Sử dụng GridSearch:

GridSearch hoạt động dựa trên nguyên tắc tìm kiếm toàn diện (exhaustive search) trên một lưới các giá trị tham số được xác định trước.

```
131 models = {
132     'Random Forest': GridSearchCV(
133         rf,
134         {'n_estimators': [100, 300, 500], 'max_depth': [10, 20, 30], 'min_samples_split': [2, 5, 10]},
135         cv=5, n_jobs=-1
136     ),
137     'XGBoost': GridSearchCV(
138         xgb,
139         {'n_estimators': [100, 300, 500], 'max_depth': [3, 5, 10], 'learning_rate': [0.01, 0.05, 0.1]},
140         cv=5, n_jobs=-1
141     ),
142     'SVM': GridSearchCV(
143         svm,
144         {'C': [0.1, 1, 10, 100], 'gamma': [0.001, 0.01, 0.1], 'kernel': ['rbf']},
145         cv=5, n_jobs=-1
146     )
147 }
```

Tham số của GridSearch:

cv=5: Sử dụng 5-fold cross-validation để đánh giá mô hình.

n_jobs=-1: Sử dụng tất cả các CPU để tăng tốc độ tính toán.

Bước 1: Định nghĩa lưới tham số: Người dùng chỉ định một tập hợp các giá trị có thể cho từng siêu tham số của mô hình (ví dụ: C = [0.1, 1, 10] cho SVM, hoặc n_estimators = [50, 100, 200] cho Random Forest). Lưới tham số là tất cả các tổ hợp có thể từ các giá trị này.

Bước 2: Huấn luyện mô hình với từng tổ hợp: GridSearch sử dụng một kỹ thuật xác thực chéo (cross-validation) (thường là k-fold cross-validation, ví dụ: 5-fold hoặc 10-fold) để huấn luyện mô hình với mỗi tổ hợp tham số. Đối với mỗi tổ hợp, mô hình được huấn luyện trên các tập huấn luyện con (training folds) và đánh giá trên các tập xác thực con (validation folds). Hiệu suất trung bình (ví dụ: độ chính xác, F1-score, hoặc lỗi trung bình) được tính toán.

Bước 3: Đánh giá và chọn tổ hợp tốt nhất: Sau khi thử nghiệm tất cả các tổ hợp, GridSearch chọn tổ hợp tham số cho kết quả tốt nhất dựa trên chỉ số đánh giá được chỉ định (metric). Tổ hợp này được sử dụng để huấn luyện lại mô hình trên toàn bộ tập huấn luyện, sau đó đánh giá trên tập kiểm tra (test set).

Bước 4: Xuất kết quả: GridSearch cung cấp tổ hợp tham số tối ưu cùng với điểm số hiệu suất tương ứng, giúp người dùng hiểu rõ hiệu quả của từng tham số.

III. Kết quả

=== Huấn luyện Random Forest ===

Độ chính xác: 0.7413

Báo cáo phân loại:

	precision	recall	f1-score	support
neutral	0.76	0.94	0.84	162
calm	0.67	0.90	0.76	155
happy	0.80	0.61	0.69	166
sad	0.71	0.52	0.60	152
angry	0.84	0.76	0.80	143
fearful	0.75	0.61	0.68	140
disgust	0.70	0.74	0.72	160
surprised	0.74	0.83	0.78	151
accuracy			0.74	1229
macro avg	0.75	0.74	0.74	1229
weighted avg	0.75	0.74	0.74	1229

=== Huấn luyện XGBoost ===

/usr/local/lib/python3.11/dist-packages/joblib/externals/loky/process_executor.p
warnings.warn(
Độ chính xác: 0.8316

Báo cáo phân loại:

	precision	recall	f1-score	support
neutral	0.85	0.97	0.90	162
calm	0.83	0.86	0.84	155
happy	0.84	0.82	0.83	166
sad	0.76	0.70	0.73	152
angry	0.89	0.83	0.86	143
fearful	0.83	0.78	0.80	140
disgust	0.79	0.82	0.81	160
surprised	0.86	0.85	0.86	151
accuracy			0.83	1229
macro avg	0.83	0.83	0.83	1229
weighted avg	0.83	0.83	0.83	1229

=== Huấn luyện SVM ===

Độ chính xác: 0.8731

Báo cáo phân loại:

	precision	recall	f1-score	support
neutral	0.84	0.98	0.91	162
calm	0.85	0.87	0.86	155
happy	0.90	0.87	0.88	166
sad	0.79	0.78	0.79	152
angry	0.91	0.90	0.90	143
fearful	0.85	0.86	0.86	140
disgust	0.90	0.83	0.86	160
surprised	0.94	0.89	0.92	151
accuracy			0.87	1229
macro avg	0.87	0.87	0.87	1229
weighted avg	0.87	0.87	0.87	1229

=== Huấn luyện Voting Ensemble ===

Độ chính xác Voting Ensemble: 0.8893

Báo cáo phân loại Voting Ensemble:

	precision	recall	f1-score	support
neutral	0.89	0.99	0.94	162
calm	0.85	0.91	0.88	155
happy	0.92	0.89	0.91	166
sad	0.81	0.78	0.79	152
angry	0.95	0.88	0.92	143
fearful	0.90	0.86	0.88	140
disgust	0.88	0.89	0.88	160
surprised	0.92	0.91	0.92	151
accuracy			0.89	1229
macro avg	0.89	0.89	0.89	1229
weighted avg	0.89	0.89	0.89	1229

Từ kết quả huấn luyện của các mô hình Random Forest, XGBoost, SVM và đặc biệt là Voting Ensemble, có thể thấy rõ rằng mô hình đã học được một cách hiệu quả các đặc trưng cảm xúc ẩn chứa trong giọng nói. Sự gia tăng đáng kể về độ chính xác từ Random Forest (0.7413) lên XGBoost (0.8316), tiếp tục đến SVM (0.8731), và đỉnh điểm là Voting Ensemble (0.8893) cho thấy sức mạnh của việc sử dụng các thuật toán khác nhau và kết hợp dự đoán của chúng.

Hiệu suất cao của Voting Ensemble: Việc kết hợp các mô hình riêng lẻ đã mang lại kết quả tốt nhất, cho thấy các mô hình có thể đang nắm bắt các khía cạnh khác nhau của dữ liệu cảm xúc, và việc "bổ khuyết" giúp giảm thiểu sai sót của từng mô hình riêng lẻ. Độ

chính xác gần 89% là một kết quả rất hứa hẹn cho bài toán nhận diện cảm xúc trên tập dữ liệu này.

Với kết quả này, có thể tự tin nói rằng mô hình đã đạt được một mức độ hiểu biết đáng kể về cách cảm xúc được thể hiện qua giọng nói trong bộ dữ liệu này, mở ra tiềm năng cho các ứng dụng thực tế như đã thảo luận trước đó.

CHƯƠNG 7: THẢO LUẬN VÀ KẾT LUẬN

I. Những bài học rút ra khi làm việc với dữ liệu âm thanh

Khi xử lý dữ liệu âm thanh, điều cốt lõi là không làm mất đi cấu trúc thời gian của nó. Thay vì làm phẳng - flatten các chuỗi đặc trưng như MFCC, hãy giữ nguyên dạng chuỗi để mô hình có thể học được sự thay đổi của âm thanh theo thời gian. Hãy sử dụng các phương pháp nâng cao đặc trưng như tính delta, giúp mô hình nhận biết được tốc độ biến đổi của âm thanh.

Để cung cấp thông tin đầy đủ nhất cho mô hình, có thể kết hợp nhiều loại đặc trưng khác nhau, ví dụ như phần trên. Việc chọn loại đặc trưng phù hợp với bài toán cụ thể và luôn thử nghiệm, đánh giá mô hình kỹ lưỡng trên nhiều khía cạnh để tìm ra cách xử lý dữ liệu tốt nhất.

Một bài học quan trọng khác khi làm việc với dữ liệu âm thanh là hiểu rõ ngữ cảnh và tính đa dạng của dữ liệu. Âm thanh có thể bị ảnh hưởng bởi vô số yếu tố như môi trường thu âm (tiếng ồn, độ vang), người nói (giọng điệu, tốc độ, cảm xúc), thiết bị thu âm và thậm chí cả văn hóa, ngôn ngữ. Việc nhận thức được sự đa dạng này giúp chúng ta thu thập và xử lý dữ liệu một cách toàn diện hơn, đồng thời xây dựng các mô hình mạnh mẽ và ít bị ảnh hưởng bởi các yếu tố bên ngoài. Điều này cũng nhấn mạnh tầm quan trọng của việc có một tập dữ liệu huấn luyện lớn và đại diện cho nhiều tình huống sử dụng thực tế.

II. Khả năng ứng dụng của mô hình

Mô hình phân loại cảm xúc thông qua giọng nói sở hữu tiềm năng ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau. Trong tương lai gần, công nghệ này có thể tích hợp vào các hệ thống tương tác người-máy, như trợ lý ảo thông minh, giúp chúng phản hồi một cách tự nhiên và phù hợp hơn với trạng thái cảm xúc của người dùng. Trong lĩnh vực dịch vụ khách hàng, mô hình có thể được sử dụng để phân tích cảm xúc của khách hàng trong các cuộc gọi hoặc tương tác trực tuyến, từ đó giúp cải thiện chất lượng dịch vụ và tăng cường sự hài lòng. Ứng dụng trong lĩnh vực y tế và tâm lý học cũng rất hứa hẹn, hỗ trợ các chuyên gia trong việc đánh giá và theo dõi trạng thái cảm xúc của bệnh nhân một cách khách quan, góp phần vào quá trình chẩn đoán và điều trị. Ngoài ra, mô hình còn có thể được ứng dụng trong ngành giải trí, ví dụ như tự động điều chỉnh nội dung hoặc gợi ý dựa trên cảm xúc của người xem hoặc người nghe. Tiềm năng thương mại hóa của công nghệ này là rất lớn, mở ra nhiều cơ hội phát triển các sản phẩm và dịch vụ thông minh, mang tính cá nhân hóa cao.

III. Ưu, nhược điểm của mô hình:

Ưu điểm: Mô hình phân loại cảm xúc qua giọng nói thu thập thông tin một cách tự nhiên và không gây phiền hà cho người dùng, khai thác một phương thức giao tiếp bản năng và quen thuộc. Khi được huấn luyện trên một tập dữ liệu phong phú và đa dạng, bao gồm nhiều ngữ cảnh, giọng điệu và cách biểu lộ cảm xúc khác nhau, mô hình có tiềm năng đạt được độ chính xác cao trong việc nhận diện một loạt các cung bậc cảm xúc, từ cơ bản đến phức tạp. Khả năng cung cấp kết quả phân tích một cách nhanh chóng và hiệu quả là một lợi thế đáng kể, đặc biệt trong các ứng dụng cần xử lý lượng lớn dữ liệu tương tác bằng giọng nói theo thời gian thực, như phân tích phản hồi của khách hàng trong các trung tâm cuộc gọi hoặc giám sát trạng thái cảm xúc trong các hệ thống tương tác ảo.

Tuy nhiên, hiệu suất của mô hình phụ thuộc một cách sâu sắc vào chất lượng và các đặc trưng được trích xuất từ dữ liệu âm thanh huấn luyện, đòi hỏi quy trình thu thập và gán nhãn tỉ mỉ, tốn kém về thời gian và nguồn lực, đồng thời cần sự hiểu biết chuyên sâu về các yếu tố ngôn ngữ, ngữ điệu, văn hóa và các dấu hiệu phi ngôn ngữ khác ảnh hưởng đến biểu hiện cảm xúc qua giọng nói. Mô hình cũng có thể gặp khó khăn trong việc phân biệt các sắc thái cảm xúc tinh tế và tương đồng, ví dụ như giữa sự lo lắng và sợ hãi nhẹ, hoặc giữa sự hứng thú và ngạc nhiên. Hơn nữa, hiệu suất của mô hình có thể bị suy giảm đáng kể bởi các yếu tố nhiễu từ môi trường thu âm, như tiếng ồn xung quanh, tạp âm hoặc chất lượng thiết bị thu âm kém, đòi hỏi các kỹ thuật tiền xử lý và chọn lọc đặc trưng mạnh mẽ và phù hợp.

IV. Đề xuất:

Để nâng cao hiệu quả và khả năng ứng dụng của mô hình phân loại cảm xúc qua giọng nói, chúng tôi đề xuất một số hướng phát triển sau:

Mở rộng và đa dạng hóa tập dữ liệu huấn luyện: Thu thập dữ liệu từ nhiều nguồn khác nhau, bao gồm nhiều độ tuổi, giới tính, giọng điệu và bối cảnh văn hóa để tăng cường tính Robustness và khả năng tổng quát hóa của mô hình. Nghiên cứu và tích hợp các đặc trưng âm thanh nâng cao: Khám phá và sử dụng các loại đặc trưng âm thanh phức tạp hơn, có khả năng nắm bắt tốt hơn các nuances cảm xúc trong giọng nói, kết hợp với các phương pháp giảm chiều dữ liệu hiệu quả. Áp dụng các kiến trúc mô hình học sâu tiên tiến: Thử nghiệm với các kiến trúc mạng nơ-ron sâu như CNN, RNN/LSTM hoặc Transformer, có khả năng tự động học các biểu diễn đặc trưng phức tạp từ dữ liệu âm thanh. Tập trung vào khả năng giải thích của mô hình: Nghiên cứu các phương pháp làm cho mô hình dễ hiểu hơn, giúp người dùng và nhà phát triển hiểu được tại sao mô hình đưa ra một dự đoán cảm xúc cụ thể. Đầu tư vào các giải pháp tiền xử lý và làm sạch dữ liệu: Phát triển các kỹ thuật hiệu quả để loại bỏ nhiễu, chuẩn hóa âm lượng và xử lý các biến thể trong giọng nói, đảm bảo chất lượng đầu vào tốt nhất cho mô hình.

Bằng việc tiếp tục nghiên cứu và phát triển theo các hướng này, chúng ta có thể khai thác tối đa tiềm năng của công nghệ phân loại cảm xúc qua giọng nói, mang lại những ứng dụng giá trị trong nhiều lĩnh vực của đời sống.

Tài liệu tham khảo:

- [1] Jurafsky, D., & Martin, J. H. (2021). *Speech and language processing* (3rd ed.). Pearson.
- [2] Jurafsky, D., & Martin, J. H. (2021). *Speech and language processing* (2nd ed.). Pearson.
- [3] G. N. L. Fabricio & V. C. J. Carlos (2015). *Introduction to Audio Analysis*. Elsevier.
- [4] Dufour, R., & L. Mikhail, J. (2020). *Deep Learning for Audio and Speech Processing*. Springer.
- [5] "Librosa Documentation," Available: <https://librosa.org/doc/latest/index.html>. [Accessed: Dec. 2024].
- [6] Smith, J. O. (1999). *A tutorial on Spectral Analysis of Sound*. Stanford University. Available: <https://ccrma.stanford.edu/~jos/sasp/>. [Accessed: Dec. 2024].
- [7] Ng, A. (2017). *Deep Learning for Speech Recognition*, Coursera, Available: <https://www.coursera.org/learn/deep-learning-speech-recognition>. [Accessed: Dec. 2024].